ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA HỆ THỐNG THÔNG TIN

BÁO CÁO ĐỀ XUẤT ĐỀ TÀI
Môn học: HỌC SÂU VÀ ỨNG DỤNG TRONG KINH DOANH

DỰ BÁO NHU CẦU HÀNG TƯƠI SỐNG CÓ XÉT HIỆN TƯỢNG HẾT HÀNG PHỤC VỤ QUẢN LÝ TỒN KHO

So sánh LightGBM và LSTM trên FreshRetailNet-50K

Lớp:	IS6109.11.CH
Giảng viên:	TS. Tạ Hoàng Thắng
Nhóm thực hiện:	Nguyễn Lý Trường Sơn – MSSV: 26848192 Tạ Nhật Hưng – MSSV: 240201038 Nguyễn Vũ Mai Phương – MSSV: 26848176 Đoàn Phạm Thanh Luân – MSSV: 26848119
Ngày nộp:	[date]

TP. HỒ CHÍ MINH — THÁNG 10 NĂM 2026

MỤC LỤC

1. TÊN ĐỀ TÀI **4**
2. TÓM TẮT **4**
3. GIỚI THIỆU **4**
3.1. Bối cảnh 4
3.2. Tầm quan trọng của bài toán 5
3.3. Vai trò của AI và học sâu 5
3.4. Động lực 5
3.5. Mục tiêu 5
3.6. Câu hỏi nghiên cứu 6
4. TỔNG QUAN NGHIÊN CỨU **6**
4.1. Dự báo nhu cầu bán lẻ và hàng tươi sống 6
4.2. Nhu cầu bị kiểm duyệt và khôi phục nhu cầu 6
4.3. Từ dự báo đến quyết định tồn kho 7
4.4. Mô hình học sâu cho chuỗi thời gian 7
4.5. Khoảng trống nghiên cứu và định vị đề tài 7
5. ĐỊNH NGHĨA BÀI TOÁN **9**
6. DỮ LIỆU **10**
6.1. Thông tin chung 10
6.2. Các trường dữ liệu 10
6.3. Thống kê kiểm chứng 11
6.4. Đặc điểm biến mục tiêu 11
6.5. Chia dữ liệu theo thời gian 12
6.6. Tiền xử lý và chuẩn bị mảng 24 giờ 12
6.7. Xử lý giờ hết hàng 12
6.8. Chuỗi cho LSTM 13
7. PHƯƠNG PHÁP DỰ KIẾN VÀ KẾ HOẠCH THỰC NGHIỆM **14**
7.1. Lựa chọn phương pháp 14
7.2. Quy trình tổng thể 14
7.3. Lớp quyết định tồn kho 15
7.4. Thiết kế thực nghiệm 16
7.5. Độ đo dự báo 16
7.6. Phân tích kết quả dự kiến 17
8. KẾT QUẢ KỲ VỌNG VÀ ĐÓNG GÓP **17**
8.1. Kết quả kỳ vọng 17
8.2. Đóng góp 17
8.3. Rủi ro và biện pháp 18
TÀI LIỆU THAM KHẢO **18**

DANH MỤC BẢNG

Bảng 1: Câu hỏi nghiên cứu và thí nghiệm trả lời.....6
Bảng 2: So sánh các nghiên cứu liên quan.....8
Bảng 3: Ứng dụng kinh doanh và tác vụ học máy.....9
Bảng 4: Đặc tả bài toán.....9
Bảng 5: Thông tin chung về FreshRetailNet-50K.....10
Bảng 6: Các trường dữ liệu và cách sử dụng.....10
Bảng 7: Thống kê kiểm chứng từ dữ liệu.....11
Bảng 8: Kế hoạch chia dữ liệu.....12
Bảng 9: Ba cách xử lý giờ hết hàng.....12
Bảng 10: Lựa chọn phương pháp.....14
Bảng 11: Cấu hình dự kiến của các mô hình.....14
Bảng 12: Chỉ tiêu đánh giá quyết định tồn kho.....15
Bảng 13: Thiết kế thực nghiệm.....16
Bảng 14: Rủi ro và biện pháp.....18

DANH MỤC HÌNH

Hình 1: Quy trình dự kiến từ dữ liệu FreshRetailNet-50K đến quyết định tồn kho.....14

1. TÊN ĐỀ TÀI

Dự báo nhu cầu hàng tươi sống có xét hiện tượng hết hàng phục vụ quản lý tồn kho: so sánh LightGBM và LSTM trên FreshRetailNet-50K (Stockout-Aware Fresh Demand Forecasting for Inventory Management: A Comparison of LightGBM and LSTM on FreshRetailNet-50K).

Bài toán kinh doanh: dự báo nhu cầu 7 ngày tới của từng sản phẩm tươi sống tại từng cửa hàng và chuyển dự báo thành mức đặt hàng, sao cho cân bằng giữa hết hàng và hao hụt. Hướng tiếp cận học sâu: mạng LSTM toàn cục học trên chuỗi nhu cầu đã xử lý giờ hết hàng; LightGBM và Seasonal Naive làm đối chứng.

2. TÓM TẮT

Với hàng tươi sống, sai số dự báo chuyển trực tiếp thành hết hàng hoặc hao hụt. Khi hết hàng, doanh số quan sát thấp hơn nhu cầu thật, khiến mô hình học từ doanh số thô dự báo thấp. Đề tài đề xuất khung dự báo nhu cầu 7 ngày có xét hiện tượng hết hàng trên FreshRetailNet-50K (50,000 chuỗi cửa hàng × sản phẩm, 898 cửa hàng, 18 thành phố, 90 ngày huấn luyện, trạng thái tồn kho theo giờ). Các mô hình gồm Seasonal Naive theo tuần (baseline), LightGBM (học máy) và LSTM (học sâu). Điểm khác biệt thứ nhất: so sánh huấn luyện trên doanh số thô với huấn luyện có che giờ hết hàng hoặc trên nhu cầu khôi phục từ hồ sơ bán theo giờ, đánh giá trên các giờ còn hàng. Thứ hai: lớp quyết định tồn kho chuyển dự báo thành mức tồn kho mục tiêu, với tồn kho an toàn ước lượng từ sai số dự báo. Độ đo gồm WAPE, WPE, MAE, RMSE và các chỉ tiêu tồn kho: tỷ lệ hết hàng, mức phục vụ, tỷ lệ đáp ứng, chi phí newsvendor tương đối. Kỳ vọng: xử lý giờ hết hàng giảm độ lệch âm và cải thiện mức phục vụ ở cùng mức tồn kho. Đóng góp: so sánh có kiểm soát LightGBM và LSTM, gắn độ chính xác dự báo với hiệu quả tồn kho.

3. GIỚI THIỆU

3.1. Bối cảnh

Rau, thịt, thủy sản, trái cây có hạn dùng tính bằng ngày; cửa hàng phải đặt hàng hằng ngày cho hàng trăm sản phẩm. Dữ liệu bán chỉ phản ánh nhu cầu khi còn hàng: khi kệ trống, doanh số ghi nhận bị cắt và phần nhu cầu còn lại không được quan sát [1], [2]. FreshRetailNet-50K của Dingdong cung cấp doanh số và trạng thái

hết hàng theo từng giờ, cho phép phân biệt "không có nhu cầu" với "không có hàng để bán" [3].

3.2. Tầm quan trọng của bài toán

- Dự báo thấp gây hết hàng, mất doanh thu và giảm hài lòng của khách; dự báo cao gây hao hụt vì hàng không bán hết trước khi hỏng [4].
- Mô hình học từ doanh số bị kiểm duyệt dự báo thấp, dẫn đến đặt ít, hết hàng nhiều hơn và dữ liệu càng bị kiểm duyệt: một vòng lặp tự củng cố [3].
- Độ chính xác dự báo chỉ có giá trị khi chuyển thành quyết định đặt hàng tốt hơn; vì vậy cần đánh giá cả ở mức quyết định tồn kho [5], [6].

3.3. Vai trò của AI và học sâu

LightGBM [7] học quan hệ phi tuyến giữa nhu cầu quá khứ, lịch, khuyến mãi, thời tiết và phân cấp sản phẩm; các phương pháp dựa trên LightGBM dẫn đầu cuộc thi M5 [8]. LSTM [9] đọc trực tiếp chuỗi quan sát theo thời gian và học phụ thuộc theo thời gian, phù hợp để kiểm định liệu học biểu diễn chuỗi có lợi hơn đặc trưng thủ công. Cả hai được huấn luyện như mô hình toàn cục trên nhiều chuỗi, sau đó dùng chung một lớp quyết định tồn kho.

3.4. Động lực

Bài báo gốc của FreshRetailNet-50K chứng minh khôi phục nhu cầu giảm độ lệch của TFT, nhưng dùng các mô hình khôi phục học sâu (TimesNet, iTransformer…) và dừng ở độ đo dự báo [3]. Câu hỏi thực tiễn còn mở: một cách khôi phục đơn giản có đủ không, LightGBM hay LSTM tận dụng tốt hơn, và cải thiện độ chính xác có chuyển thành mức phục vụ cao hơn hoặc chi phí thấp hơn không.

3.5. Mục tiêu

Mục tiêu tổng quát: xây dựng và đánh giá khung dự báo nhu cầu hàng tươi sống có xét hiện tượng hết hàng, kèm lớp quyết định tồn kho.

Mục tiêu cụ thể:

- Chuẩn bị dữ liệu FreshRetailNet-50K; xử lý mảng 24 giờ và giờ hết hàng.
- Xây dựng phương pháp khôi phục nhu cầu đơn giản từ hồ sơ bán theo giờ.
- Xây dựng Seasonal Naive, LightGBM và LSTM cho tầm dự báo 7 ngày.
- So sánh huấn luyện trên doanh số thô và trên dữ liệu đã xử lý giờ hết hàng.
- Chuyển dự báo thành mức tồn kho mục tiêu; đánh giá bằng chỉ tiêu tồn kho.

3.6. Câu hỏi nghiên cứu

Bảng 1: *Câu hỏi nghiên cứu và thí nghiệm trả lời*

Mã	Câu hỏi nghiên cứu	Thí nghiệm trả lời (mục 7.4)
RQ1	LightGBM và LSTM có dự báo nhu cầu 7 ngày chính xác hơn Seasonal Naive theo tuần không?	E1 so với E2–E5
RQ2	Che giờ hết hàng hoặc khôi phục nhu cầu có giảm sai số và độ lệch trên các giờ còn hàng không?	E2 so với E3, E3m; E4 so với E5
RQ3	LightGBM so với LSTM như thế nào khi dùng cùng dữ liệu và đặc trưng?	E2 so với E4; E3 so với E5
RQ4	Cải thiện độ chính xác có chuyển thành mức phục vụ cao hơn và chi phí tồn kho thấp hơn không?	Lớp tồn kho áp dụng cho E1–E5
RQ5	Khuyến mãi và thời tiết đóng góp bao nhiêu vào độ chính xác?	A1, A2 so với E3

4. TỔNG QUAN NGHIÊN CỨU

4.1. Dự báo nhu cầu bán lẻ và hàng tươi sống

Fildes và cộng sự [10] tổng quan dự báo bán lẻ: dữ liệu chi tiết ở cấp sản phẩm cho phép gộp dữ liệu giữa các chuỗi (pooling), khuyến mãi là thách thức lớn, và nhiều phương pháp phức tạp chưa có bằng chứng thuyết phục về giá trị. Huber và cộng sự [4] dự báo nhu cầu hằng ngày cho chuỗi bánh mì công nghiệp bằng ARIMA đa biến trên phân cấp mở rộng theo cụm hồ sơ bán trong ngày, cho thấy có thể tăng tính sẵn có mà vẫn hạn chế hao hụt. Miguéis và cộng sự [11] dự báo nhu cầu cá tươi hằng ngày cho một cửa hàng của nhà bán lẻ châu Âu, có xét nhu cầu bị kiểm duyệt; LSTM nhìn chung tốt nhất so với mạng truyền thẳng, SVR, Random Forest và Holt-Winters. Trong M5, mọi phương pháp top 50 là học máy và phần lớn dựa trên LightGBM [8].

4.2. Nhu cầu bị kiểm duyệt và khôi phục nhu cầu

Conlon và Mortimer [1] dùng dữ liệu máy bán hàng tự động có trạng thái hàng theo chu kỳ 4 giờ, cho thấy bỏ qua thay đổi về tính sẵn có làm lệch ước lượng nhu cầu. Amjad và Shah [2] ước lượng nhu cầu thật từ quan sát nhiễu, có thể bị kiểm duyệt, bằng hoàn thiện ma trận (USVT) trên nhiều chuỗi, kiểm chứng trên dữ liệu Walmart. Wang và cộng sự [3] giới thiệu FreshRetailNet-50K và quy trình hai giai đoạn: khôi phục nhu cầu theo giờ rồi dự báo 7 ngày. Với TFT trên toàn bộ dữ liệu, WAPE giảm từ 31.75% (doanh số thô) xuống 29.02% (khôi phục bằng TimesNet)

và 29.26% (iTransformer); WPE từ −7.37% chuyển thành 2.58% và 0.57%. Đánh giá chỉ thực hiện trên các giai đoạn không hết hàng.

4.3. Từ dự báo đến quyết định tồn kho

Mô hình newsvendor cân bằng chi phí đặt thiếu và đặt thừa cho hàng dễ hỏng; mức đặt tối ưu là một phân vị của phân phối nhu cầu [12]. Huber và cộng sự [5] giải bài toán newsvendor dựa trên dữ liệu cho chuỗi bánh mì Đức; học máy vượt trội khi dữ liệu đủ lớn, và lợi ích từ dự báo tốt hơn chiếm ưu thế so với các lợi ích khác của phương pháp dựa trên dữ liệu. Trapero và cộng sự [6] ước lượng tồn kho an toàn từ sai số dự báo bằng ước lượng mật độ nhân và GARCH khi sai số không độc lập, phân phối chuẩn; cải thiện mức phục vụ chu kỳ, vốn tồn kho và lượng thiếu hàng. Các định nghĩa mức phục vụ chu kỳ và tỷ lệ đáp ứng theo Silver và cộng sự [13].

4.4. Mô hình học sâu cho chuỗi thời gian

LSTM [9] dùng ô nhớ và các cổng để học phụ thuộc dài hạn. TFT [14] kết hợp lớp hồi quy và self-attention, xử lý biến tĩnh và biến biết trước trong tương lai, có khả năng diễn giải. DLinear [15] là mô hình tuyến tính một lớp phân rã xu hướng – mùa vụ, vượt các mô hình Transformer trên chín bộ dữ liệu dự báo dài hạn. Trên FreshRetailNet-50K, TFT ổn định nhất trong ba baseline SSA, TFT, DLinear; DLinear tốt ở nhóm bán nhiều nhưng dự báo quá cao ở nhóm bán ít sau khôi phục [3].

4.5. Khoảng trống nghiên cứu và định vị đề tài

- Phần lớn nghiên cứu dự báo hàng tươi sống dùng dữ liệu riêng, không có nhãn hết hàng; nghiên cứu khôi phục nhu cầu thường không đi đến quyết định tồn kho.
- Trên FreshRetailNet-50K chưa có so sánh LightGBM với một mô hình học sâu dạng chuỗi trong cùng thiết kế, và chưa kiểm định một phương pháp khôi phục đơn giản.
- Cải thiện WAPE, WPE chưa được chuyển thành mức phục vụ, tỷ lệ đáp ứng và chi phí.

Đề tài so sánh Seasonal Naive, LightGBM và LSTM trên ba cách xử lý giờ hết hàng (thô, che, khôi phục) và đánh giá ở cả mức dự báo lẫn mức quyết định tồn kho. TFT và DLinear được tham chiếu qua kết quả công bố [3], không huấn luyện lại.

Bảng 2 tóm tắt dữ liệu, phương pháp, độ đo và ưu điểm, hạn chế của các nghiên cứu chính.

Bảng 2: *So sánh các nghiên cứu liên quan*

Nghiên cứu	Dữ liệu	Phương pháp	Độ đo	Ưu điểm / hạn chế
Huber et al. (2017) [4]	Chuỗi bánh mì, theo ngày	ARIMA đa biến, phân cấp theo cụm	Sẵn có, hao hụt	Gắn dự báo với vận hành; mô hình thống kê
Miguéis et al. (2022) [11]	Cá tươi, một cửa hàng	LSTM, FNN, SVR, RF, Holt-Winters	RMSE, MAE, MPE	Có xét kiểm duyệt; một cửa hàng, dữ liệu riêng
Conlon & Mortimer (2013) [1]	Máy bán hàng tự động, trạng thái 4 giờ	Ước lượng nhu cầu kinh tế lượng	Độ lệch ước lượng	Chứng minh lệch do hết hàng; không phải dự báo
Amjad & Shah (2017) [2]	Walmart, mô phỏng	Hoàn thiện ma trận (USVT)	MSE	Có bảo đảm lý thuyết; không có nhãn hết hàng
Makridakis et al. (2022) [8]	M5: 42,840 chuỗi Walmart	LightGBM, thống kê, học sâu	WRMSSE	LightGBM dẫn đầu; không xét hết hàng
Qin et al. (2011) [12]	Tổng quan lý thuyết	Mô hình newsvendor	–	Nền tảng chính sách; không gắn dự báo cụ thể
Huber et al. (2019) [5]	Chuỗi bánh mì Đức	Newsvendor dựa trên dữ liệu, ML, hồi quy phân vị	Chi phí newsvendor	Nối dự báo với quyết định; doanh số chưa hiệu chỉnh hết hàng
Trapero et al. (2019) [6]	Mô phỏng, nhà sản xuất	Tồn kho an toàn: KDE, GARCH	Mức phục vụ, vốn tồn kho	Bỏ giả định sai số chuẩn; không phải hàng tươi sống
Lim et al. (2021) [14]	Nhiều bộ dữ liệu thực	TFT (attention, đa tầm)	Sai số đa tầm	Diễn giải được; tốn tài nguyên
Zeng et al. (2023) [15]	Chín bộ dữ liệu dự báo dài hạn	DLinear (tuyến tính, phân rã)	MSE, MAE	Đơn giản, mạnh; không dùng biến ngoại sinh
Wang et al. (2025) [3]	FreshRetailNet-50K	Khôi phục (TimesNet…) + SSA, TFT, DLinear	WAPE, WPE	Nhãn hết hàng theo giờ; chưa có LightGBM, chưa đánh giá tồn kho

5. ĐỊNH NGHĨA BÀI TOÁN

Ký hiệu: i là chuỗi cửa hàng × sản phẩm, t là ngày, h = 0…23 là giờ; y(i,t,h) là doanh số giờ, s(i,t,h) = 1 nếu hết hàng trong giờ h (theo hours_stock_status); Y(i,t) là tổng y(i,t,h) theo h (doanh số ngày), D(i,t) là nhu cầu thật (không quan sát được khi có giờ hết hàng).

Bảng 3: *Ứng dụng kinh doanh và tác vụ học máy*

Ứng dụng kinh doanh	Tác vụ học máy tương ứng
Đặt hàng hằng ngày cho từng sản phẩm tại từng cửa hàng	Dự báo đa tầm h = 1…7 ngày, hồi quy có giám sát
Hiệu chỉnh doanh số bị cắt do hết hàng	Che dữ liệu hoặc khôi phục nhu cầu theo giờ
Xác định mức tồn kho mục tiêu và tồn kho an toàn	Phân vị dự báo từ phân phối sai số; tối ưu newsvendor
Đánh giá đánh đổi hết hàng – hao hụt	Mô phỏng chính sách; chỉ tiêu mức phục vụ và chi phí

Bảng 4: *Đặc tả bài toán*

Thành phần	Mô tả
Đơn vị dự báo	Chuỗi cửa hàng × sản phẩm (50,000 chuỗi); bước thời gian = ngày
Đầu vào	Nhu cầu quá khứ (thô hoặc đã xử lý giờ hết hàng); số giờ hết hàng quá khứ; phân cấp thành phố – cửa hàng – nhóm quản lý – ba cấp danh mục – sản phẩm; lịch; khuyến mãi (discount, activity_flag); thời tiết
Biến biết trước	discount, activity_flag, holiday_flag, thời tiết của 7 ngày tới (giả định như bài báo gốc [3])
Đầu ra	$\hat{D}(i,T+h)$, h = 1…7, và mức tồn kho mục tiêu S(i,T+h)
Loại tác vụ	Hồi quy có giám sát trên chuỗi thời gian; mô hình toàn cục
Tầm dự báo	7 ngày, trùng tập eval và bài báo gốc [3]
Mục tiêu	Giảm WAPE và độ lớn của WPE trên giờ còn hàng; đạt mức phục vụ mục tiêu với chi phí tương đối thấp nhất

6. DỮ LIỆU

6.1. Thông tin chung

Bảng 5: *Thông tin chung về FreshRetailNet-50K*

Thuộc tính	Giá trị
Tên, đơn vị phát hành	FreshRetailNet-50K; Dingdong (Trung Quốc), 2025 [3], [16]
Liên kết	https://huggingface.co/datasets/Dingdong-Inc/FreshRetailNet-50K; mã nguồn baseline [17]
Giấy phép	CC BY 4.0 [16]
Quy mô	50,000 chuỗi cửa hàng × sản phẩm; 898 cửa hàng; 18 thành phố
Sản phẩm	865 product_id (thẻ dữ liệu [16], kiểm đếm trực tiếp); bài báo ghi 863 SKU [3]
Thời gian	train: 28/03/2024 – 25/06/2024 (90 ngày); eval: 26/06/2024 – 02/07/2024 (7 ngày)
Số dòng	train 4,500,000 = 50,000 × 90; eval 350,000 = 50,000 × 7
Độ phân giải	Một dòng/chuỗi/ngày, kèm hai mảng 24 giờ: hours_sale, hours_stock_status
Hết hàng	19.9% số giờ trong khung 6:00–22:00 của tập train ở trạng thái hết hàng

> *Ghi chú: số liệu trong Bảng 5 được nhóm kiểm đếm trực tiếp từ tệp parquet trên Hugging Face (03/10/2026).*

6.2. Các trường dữ liệu

Bảng 6: *Các trường dữ liệu và cách sử dụng*

Nhóm	Trường	Kiểu	Mô tả và cách dùng
Phân cấp	city_id, store_id, management_group_id, first/second/third_category_id, product_id	Mã số	18 thành phố, 898 cửa hàng, 7 nhóm quản lý, 32/84/233 danh mục, 865 sản phẩm; embedding cho LSTM
Thời gian	dt	Chuỗi ngày	Sinh thứ trong tuần, ngày trong tháng
Mục tiêu	sale_amount	Số thực ≥ 0	Doanh số ngày (chuẩn hóa) = tổng hours_sale
Theo giờ	hours_sale	Mảng 24	Doanh số từng giờ 0–23
Hết hàng	hours_stock_status	Mảng 24	1 = hết hàng trong giờ đó
Hết hàng	stock_hour6_22_cnt	Số nguyên	Số giờ hết hàng 6:00–22:00 (0–16)
Khuyến mãi	discount, activity_flag	Số thực, 0/1	Tỷ lệ giá (1.0 = không giảm); cờ khuyến mãi
Lịch	holiday_flag	0/1	1 vào cuối tuần và ngày lễ
Thời tiết	precpt, avg_temperature, avg_humidity, avg_wind_level	Số thực	Mưa, nhiệt độ, độ ẩm, sức gió theo cửa hàng – ngày

6.3. Thống kê kiểm chứng

Bảng 7: *Thống kê kiểm chứng từ dữ liệu*

Chỉ số	Train	Eval
Tỷ lệ giờ hết hàng, 6:00–22:00	19.9%	18.1%
Ngày có ít nhất 1 giờ hết hàng (6:00–22:00)	44.3%	41.0%
Ngày hết hàng cả 16 giờ (6:00–22:00)	4.0%	3.6%
Ngày có doanh số bằng 0	4.5%	4.2%
Ngày có discount < 1	51.5%	49.5%
Ngày có activity_flag = 1	37.8%	33.0%
Ngày có holiday_flag = 1	34.4%	28.6%
Giá trị thiếu	0	0

Kiểm tra nhất quán: tổng hours_sale bằng sale_amount ở mọi dòng (sai khác lớn nhất cỡ 10^{-14}); stock_hour6_22_cnt bằng tổng hours_stock_status của các giờ 6–21 ở 100% dòng, xác nhận giá trị 1 nghĩa là hết hàng.

6.4. Đặc điểm biến mục tiêu

- sale_amount là số thực không âm, lệch phải (train: trung vị 0.7, trung bình 1.0, lớn nhất 44.9 đơn vị chuẩn hóa). Vì chuẩn hóa là phép nhân một hệ số toàn cục [16], các độ đo tỷ lệ (WAPE, WPE, tỷ lệ đáp ứng, chi phí tương đối) không đổi; MAE, RMSE tính theo đơn vị chuẩn hóa.
- Ở mức giờ, dữ liệu rất thưa: chỉ 28.6% giờ còn hàng có doanh số dương. Doanh số tập trung lúc 8–10 giờ và 16 giờ, khớp mô tả của bài báo về hai đỉnh trong ngày [3].
- Tỷ lệ giờ hết hàng thấp nhất lúc 7 giờ (5.0%) và tăng dần tới khoảng 41% lúc 21 giờ. Bài báo mô tả cùng dạng chu kỳ nhưng với mức khác (dưới 2% sau đợt bổ sung 6 giờ, 26% lúc 20 giờ) [3]; nhóm sẽ báo cáo theo định nghĩa tính trực tiếp từ hours_stock_status.
- Giờ hết hàng không hoàn toàn bằng 0: 2.9% giờ hết hàng có doanh số dương (hết hàng giữa giờ), chiếm 2.5% tổng doanh số.

6.5. Chia dữ liệu theo thời gian

Bảng 8: *Kế hoạch chia dữ liệu*

Tập	Khoảng thời gian	Số ngày	Mục đích
Huấn luyện	28/03/2024 – 18/06/2024	83	Huấn luyện; ước lượng hồ sơ giờ
Validation	19/06/2024 – 25/06/2024	7	Chọn siêu tham số; ước lượng phân phối sai số cho tồn kho an toàn
Kiểm tra	26/06/2024 – 02/07/2024 (tập eval)	7	Đánh giá dự báo và chính sách tồn kho

Sau khi chọn siêu tham số, mô hình được huấn luyện lại trên 90 ngày của tập train; phân phối sai số dùng cho tồn kho an toàn vẫn lấy từ dự báo ngoài mẫu trên validation. Nếu tài nguyên cho phép, bổ sung rolling-origin với nhiều cửa sổ 7 ngày trong tập train.

6.6. Tiền xử lý và chuẩn bị mảng 24 giờ

- Đọc hai mảng giờ thành ma trận N × 24 (NumPy) thay vì trải thành khoảng 108 triệu dòng giờ; giữ dữ liệu ngày ở dạng bảng.
- Kiểm tra nhất quán như mục 6.3 cho cả train và eval.
- Sinh đặc trưng từ mảng giờ: số giờ hết hàng, giờ bắt đầu hết hàng đầu tiên, doanh số trước giờ hết hàng, tỷ lệ hồ sơ giờ còn hàng; dùng ở dạng trễ (chỉ thông tin trước mốc dự báo).
- discount: 0.36% dòng có giá trị 0, không hợp lý với định nghĩa tỷ lệ giá, được coi là thiếu và điền theo trung vị của sản phẩm trong cùng trạng thái activity_flag; vài giá trị lớn hơn 1 được cắt về 1.
- Thứ trong tuần lấy từ dt, không lấy từ holiday_flag (cờ này gộp cuối tuần và ngày lễ).
- Ép kiểu (int16, float32, category) để giảm bộ nhớ.

6.7. Xử lý giờ hết hàng

Bảng 9: *Ba cách xử lý giờ hết hàng*

Cách	Mục tiêu huấn luyện	Mô tả
Thô (raw)	$Y(i,t)$	Dùng doanh số quan sát làm nhu cầu (như bài báo gốc)
Che (mask)	$Y(i,t)$, trọng số 0 ngày bị kiểm duyệt	Bỏ khỏi hàm mất mát các ngày có hơn k giờ hết hàng (dự kiến k = 2)
Khôi phục	$\tilde{D}(i,t)$	Ước lượng nhu cầu bị mất trong giờ hết hàng từ hồ sơ giờ

Phương pháp khôi phục đơn giản dựa trên hồ sơ trong ngày:

- Hồ sơ p(i,h) là tỷ trọng doanh số theo giờ, ước lượng trên các ngày còn hàng đủ 16 giờ của chuỗi i trong tập huấn luyện, tách ngày thường và cuối tuần; co về hồ sơ của cửa hàng × danh mục cấp 3 khi chuỗi có ít ngày còn hàng.
- Nhu cầu ngày khôi phục: $\tilde{D}(i,t) = Y^{+}(i,t) / P^{+}(i,t)$, với Y^{+} là doanh số trong các giờ còn hàng và P^{+} là tổng p(i,h) trên các giờ đó; giờ hết hàng nhận max(y, $\tilde{D} \cdot p(i,h)$).
- Khi P^{+} nhỏ hơn ngưỡng (dự kiến 0.3), dùng trung bình nhu cầu cùng thứ của các tuần trước; giá trị khôi phục được chặn trên bởi phân vị 99 của chuỗi. Chạy thử notebook trên tập con 5,000 chuỗi cho thấy ngưỡng này áp dụng cho 8.2% chuỗi – ngày trong 90 ngày huấn luyện; các ngày hết hàng cả 16 giờ (4.0%, mục 6.3) chỉ là một phần trong số đó.
- Kiểm chứng như bài báo gốc [3]: che nhân tạo một số giờ trên các ngày còn hàng đủ, khôi phục rồi đo WAPE, WPE so với giá trị thật.

6.8. Chuỗi cho LSTM

- Mỗi mẫu gồm cửa sổ quá khứ L = 28 ngày (bốn chu kỳ tuần, phù hợp chuỗi chỉ 90 ngày) và đầu ra 7 ngày; cửa sổ trượt bước 1 ngày, cho khoảng 49 mẫu mỗi chuỗi trong 83 ngày huấn luyện.
- Đầu vào theo ngày: nhu cầu (thô hoặc khôi phục) chuẩn hóa theo chuỗi, số giờ hết hàng, discount, activity_flag, holiday_flag, thứ trong tuần, bốn biến thời tiết.
- Biến biết trước của 7 ngày tới đi vào nhánh riêng; định danh phân cấp qua lớp embedding.
- Chuẩn hóa: chia cho trung bình nhu cầu của chuỗi trên tập huấn luyện; biến thời tiết dùng StandardScaler fit trên tập huấn luyện.
- Tính khả thi: phát triển trên tập con khoảng 5,000 chuỗi lấy mẫu phân tầng theo thành phố, nhóm quản lý và mức hết hàng; mở rộng ra toàn bộ 50,000 chuỗi nếu tài nguyên cho phép. Mọi mô hình dùng cùng tập con.

7. PHƯƠNG PHÁP DỰ KIẾN VÀ KẾ HOẠCH THỰC NGHIỆM

7.1. Lựa chọn phương pháp

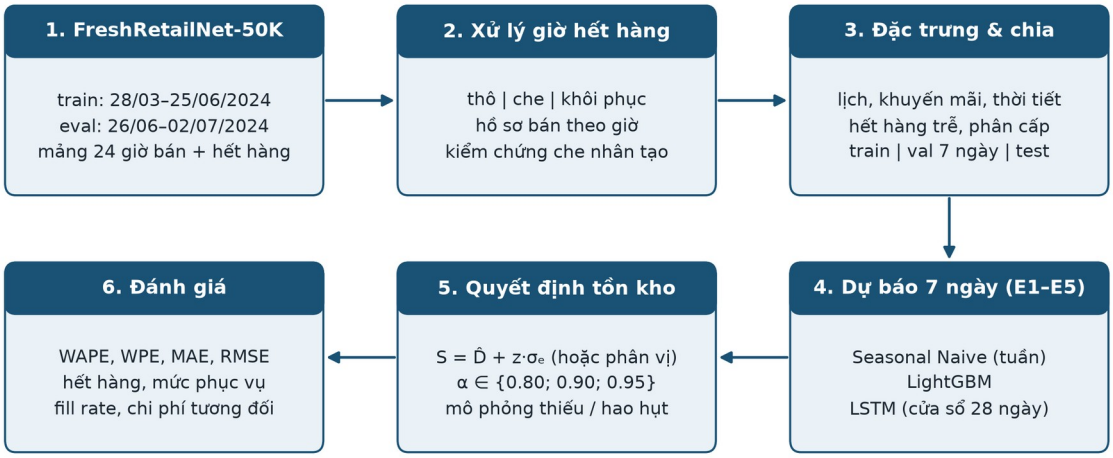
Bảng 10: *Lựa chọn phương pháp*

Vai trò	Mô hình	Lý do lựa chọn
Baseline	Seasonal Naive (tuần)	Mốc tham chiếu đơn giản nhất có tôn trọng chu kỳ tuần, chu kỳ duy nhất quan sát được trong 90 ngày: $\hat{D}(T+h) = Y(T+h-7)$ với $h = 1…7$; mọi mô hình phải vượt mốc này
Học máy	LightGBM	Mạnh trên dữ liệu dạng bảng; học quan hệ phi tuyến giữa lịch, khuyến mãi, thời tiết và phân cấp; huấn luyện hiệu quả [7]; là nền tảng của phần lớn phương pháp dẫn đầu M5 [8]; chưa được đánh giá trên FreshRetailNet-50K
Học sâu	LSTM	Xử lý quan sát dưới dạng chuỗi thời gian, được thiết kế để học phụ thuộc theo thời gian [9]; nhẹ hơn TFT, phù hợp chuỗi ngắn; đã cho kết quả tốt với cá tươi có xét kiểm duyệt [11]

Bảng 11: *Cấu hình dự kiến của các mô hình*

Mô hình	Cấu hình dự kiến
Seasonal Naive	Lặp lại 7 ngày cuối trước mốc dự báo, trên doanh số thô
LightGBM	Mô hình toàn cục, dự báo trực tiếp với biến tầm h; trễ cùng thứ $y(T+h-7)$, $y(T+h-14)$, trung bình trượt 7/14/28 ngày tính tại mốc T; hàm mất mát L2 (thử Tweedie); early stopping trên validation
LSTM	Encoder LSTM 1–2 lớp cho 28 ngày quá khứ; embedding phân cấp; nhánh biến biết trước; đầu ra 7 giá trị; MSE; Adam; early stopping; lặp với nhiều seed

7.2. Quy trình tổng thể



Hình 1: *Quy trình dự kiến từ dữ liệu FreshRetailNet-50K đến quyết định tồn kho*

7.3. Lớp quyết định tồn kho

Giả định chính sách: xem xét định kỳ hằng ngày, hàng về đầu ngày (bộ dữ liệu ghi nhận đợt bổ sung lúc 6 giờ [3]), hàng tồn cuối ngày được coi là hao hụt (giả định thận trọng cho hàng tươi sống, tương ứng mô hình newsvendor [12]).

- Mức tồn kho mục tiêu: $S(i,t) = \hat{D}(i,t) + SS(i)$, với $SS(i) = z(\alpha) \cdot \sigma_e(i)$ và $\sigma_e(i)$ là độ lệch chuẩn sai số dự báo ngoài mẫu trên tuần validation, đo so với nhu cầu khôi phục $\tilde{D}$. Mỗi chuỗi chỉ có một tuần validation, tức một sai số cho mỗi tầm h, nên $\sigma_e(i)$ được gộp qua các tầm $h = 1…7$ rồi co về nhóm chuỗi (nhóm quản lý × ngũ phân vị doanh số) [13].
- Phương án phi tham số: SS là phân vị α của phân phối sai số thực nghiệm, phù hợp khi sai số không chuẩn [6].
- Mức phục vụ mục tiêu $\alpha \in \{0.80; 0.90; 0.95\}$, tương ứng tỷ lệ chi phí thiếu/thừa $c_1/c_2 = \alpha/(1-\alpha)$ trong newsvendor (c_1: chi phí thiếu một đơn vị, c_2: chi phí hao hụt một đơn vị).
- Nhu cầu thật để mô phỏng: các ngày kiểm tra không có giờ hết hàng 6–22 (doanh số quan sát ≈ nhu cầu); phân tích độ nhạy dùng nhu cầu khôi phục cho toàn bộ ngày.

Bảng 12: *Chỉ tiêu đánh giá quyết định tồn kho*

Chỉ tiêu	Công thức	Ý nghĩa
Tỷ lệ hết hàng	Tỷ lệ chuỗi – ngày có D > S	Tần suất thiếu hàng
Mức phục vụ chu kỳ	1 − tỷ lệ hết hàng; so với α mục tiêu	Mức đạt được so với cam kết
Tỷ lệ đáp ứng (fill rate)	$\Sigma \min(S, D) / \Sigma D$	Phần nhu cầu được đáp ứng
Tỷ lệ hao hụt	$\Sigma \max(S - D, 0) / \Sigma D$	Phần hàng dư so với nhu cầu
Chi phí newsvendor tương đối	$[c_1 \Sigma(D - S)^+ + c_2 \Sigma(S - D)^+] /$ chi phí của E1	So sánh không phụ thuộc thang đo; sales đã chuẩn hóa

7.4. Thiết kế thực nghiệm

Bảng 13: *Thiết kế thực nghiệm*

Thí nghiệm	Mô hình	Dữ liệu huấn luyện	Đặc trưng
E1	Seasonal Naive	Doanh số thô	Y(T+h−7)
E2	LightGBM	Doanh số thô	Nhu cầu quá khứ + lịch + khuyến mãi + thời tiết
E3	LightGBM	Nhu cầu khôi phục	Như E2 + đặc trưng hết hàng trễ
E3m (so sánh phụ)	LightGBM	Doanh số thô, che ngày bị kiểm duyệt	Như E3
E4	LSTM	Doanh số thô	Như E2, chuỗi 28 ngày
E5	LSTM	Nhu cầu khôi phục	Như E3, chuỗi 28 ngày
A1 (loại bỏ)	LightGBM	Nhu cầu khôi phục	E3 bỏ thời tiết
A2 (loại bỏ)	LightGBM	Nhu cầu khôi phục	E3 bỏ discount, activity_flag

Mỗi phép so sánh trả lời một câu hỏi: E1 so với E2–E5 đo mức cải thiện so với baseline (RQ1); E2 so với E3 và E3m, E4 so với E5 đo tác động của việc xử lý giờ hết hàng (RQ2); E2 so với E4 và E3 so với E5 so sánh học máy với học sâu (RQ3); A1, A2 so với E3 đo đóng góp của thời tiết và khuyến mãi (RQ5). Dự báo của E1–E5 cùng đi qua lớp tồn kho ở mục 7.3 để trả lời RQ4. Mọi thí nghiệm dùng cùng tập con, cùng cách chia và cùng độ đo.

7.5. Độ đo dự báo

Đánh giá trên giờ còn hàng, theo nguyên tắc của bài báo gốc [3]: với mỗi chuỗi – ngày kiểm tra, Y^+ là doanh số trong các giờ còn hàng và $\hat{D}^+ = \hat{D} \cdot P^+$ là phần dự báo tương ứng (P^+ tính từ hồ sơ giờ ước lượng trên train). Với ngày còn hàng đủ, $\hat{D}^+ = \hat{D}$.

- $\text{WAPE} = \Sigma|\hat{D}^+ - Y^+| \,/\, \Sigma Y^+$: sai số tuyệt đối có trọng số, không phụ thuộc thang đo.
- $\text{WPE} = \Sigma(\hat{D}^+ - Y^+) \,/\, \Sigma Y^+$: độ lệch; âm là dự báo thấp.
- MAE, RMSE tính trên $\hat{D}^+$ và Y^+ theo đơn vị chuẩn hóa; RMSE nhạy với đỉnh nhu cầu.
- Kiểm tra độ vững: tính lại các độ đo chỉ trên các ngày còn hàng đủ 16 giờ.

7.6. Phân tích kết quả dự kiến

- Theo nhóm: doanh số cao/thấp (chia theo trung vị), mức hết hàng của chuỗi, ngày có/không khuyến mãi, cuối tuần/ngày lễ, nhóm quản lý.
- Theo tầm dự báo h = 1…7.
- Mức độ quan trọng đặc trưng: gain và SHAP cho LightGBM; permutation importance cho LSTM.

8. KẾT QUẢ KỲ VỌNG VÀ ĐÓNG GÓP

8.1. Kết quả kỳ vọng

Đề tài ở giai đoạn đề xuất; các nhận định sau là giả thuyết sẽ được kiểm định:

- LightGBM và LSTM có WAPE thấp hơn Seasonal Naive (RQ1).
- Huấn luyện trên doanh số thô cho WPE âm; che hoặc khôi phục giờ hết hàng đưa WPE về gần 0 và giảm WAPE, phù hợp xu hướng bài báo gốc báo cáo với TFT [3] (RQ2).
- LightGBM được kỳ vọng cạnh tranh hoặc tốt hơn LSTM trên chuỗi ngắn 90 ngày; LSTM có thể có lợi ở nhóm bán nhiều (RQ3).
- Dự báo ít lệch hơn đạt mức phục vụ mục tiêu với tồn kho an toàn nhỏ hơn, giảm chi phí tương đối (RQ4).
- Khuyến mãi được kỳ vọng đóng góp nhiều hơn thời tiết (RQ5).

8.2. Đóng góp

- So sánh có kiểm soát LightGBM và LSTM trên FreshRetailNet-50K với ba cách xử lý giờ hết hàng.
- Phương pháp khôi phục nhu cầu đơn giản, có kiểm chứng, dễ triển khai.
- Đánh giá dự báo bằng chỉ tiêu tồn kho, nối độ chính xác với quyết định đặt hàng.

8.3. Rủi ro và biện pháp

Bảng 14: *Rủi ro và biện pháp*

Rủi ro	Biện pháp
Chuỗi chỉ 90 ngày: chỉ có chu kỳ tuần	Cửa sổ LSTM 28 ngày; không mô hình hóa mùa vụ năm
Doanh số đã chuẩn hóa	Ưu tiên độ đo tỷ lệ; chi phí báo cáo tương đối
Nhu cầu thật không quan sát khi hết hàng	Đánh giá trên giờ còn hàng; độ nhạy với nhu cầu khôi phục
Chọn ngày còn hàng gây thiên lệch	Báo cáo song song hai cách đánh giá
Thời tiết tương lai giả định đã biết	Nêu rõ giả định; thử A1 bỏ thời tiết
Chi phí tính toán	Tập con 5,000 chuỗi; ép kiểu; mảng NumPy

TÀI LIỆU THAM KHẢO

[1] C. T. Conlon and J. H. Mortimer, "Demand estimation under incomplete product availability," *American Economic Journal: Microeconomics*, vol. 5, no. 4, pp. 1–30, 2013, doi: 10.1257/mic.5.4.1.

[2] M. J. Amjad and D. Shah, "Censored demand estimation in retail," *Proc. ACM on Measurement and Analysis of Computing Systems*, vol. 1, no. 2, Art. no. 31, 2017, doi: 10.1145/3154489.

[3] Y. Wang, J. Gu, L. Long, X. Li, L. Shen, Z. Fu, X. Zhou, and X. Jiang, "FreshRetailNet-50K: A stockout-annotated censored demand dataset for latent demand recovery and forecasting in fresh retail," arXiv:2505.16319, 2025. [Online]. Available: https://arxiv.org/abs/2505.16319

[4] J. Huber, A. Gossmann, and H. Stuckenschmidt, "Cluster-based hierarchical demand forecasting for perishable goods," *Expert Systems with Applications*, vol. 76, pp. 140–151, 2017, doi: 10.1016/j.eswa.2017.01.022.

[5] J. Huber, S. Müller, M. Fleischmann, and H. Stuckenschmidt, "A data-driven newsvendor problem: From data to decision," *European Journal of Operational Research*, vol. 278, no. 3, pp. 904–915, 2019, doi: 10.1016/j.ejor.2019.04.043.

[6] J. R. Trapero, M. Cardós, and N. Kourentzes, "Empirical safety stock estimation based on kernel and GARCH models," *Omega*, vol. 84, pp. 199–211, 2019, doi: 10.1016/j.omega.2018.05.004.

[7] G. Ke *et al.*, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems 30*, 2017. [Online]. Available: https://proceedings.neurips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html

[8] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "M5 accuracy competition: Results, findings, and conclusions," *International Journal of Forecasting*, vol. 38, no. 4, pp. 1346–1364, 2022, doi: 10.1016/j.ijforecast.2021.11.013.

[9] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[10] R. Fildes, S. Ma, and S. Kolassa, "Retail forecasting: Research and practice," *International Journal of Forecasting*, vol. 38, no. 4, pp. 1283–1318, 2022, doi: 10.1016/j.ijforecast.2019.06.004.

[11] V. L. Miguéis, A. Pereira, J. Pereira, and G. Figueira, "Reducing fresh fish waste while ensuring availability: Demand forecast using censored data and machine learning," *Journal of Cleaner Production*, vol. 359, Art. no. 131852, 2022, doi: 10.1016/j.jclepro.2022.131852.

[12] Y. Qin, R. Wang, A. J. Vakharia, Y. Chen, and M. M. H. Seref, "The newsvendor problem: Review and directions for future research," *European Journal of Operational Research*, vol. 213, no. 2, pp. 361–374, 2011, doi: 10.1016/j.ejor.2010.11.024.

[13] E. A. Silver, D. F. Pyke, and D. J. Thomas, *Inventory and Production Management in Supply Chains*, 4th ed. Boca Raton, FL, USA: CRC Press, 2017, doi: 10.1201/9781315374406.

[14] B. Lim, S. Ö. Arık, N. Loeff, and T. Pfister, "Temporal Fusion Transformers for interpretable multi-horizon time series forecasting," *International Journal of Forecasting*, vol. 37, no. 4, pp. 1748–1764, 2021, doi: 10.1016/j.ijforecast.2021.03.012.

[15] A. Zeng, M. Chen, L. Zhang, and Q. Xu, "Are transformers effective for time series forecasting?," in *Proc. AAAI Conference on Artificial Intelligence*, vol. 37, no. 9, 2023, pp. 11121–11128, doi: 10.1609/aaai.v37i9.26317.

[16] Dingdong-Inc, "FreshRetailNet-50K," Hugging Face dataset card, v1.0, 2025. [Online]. Available: https://huggingface.co/datasets/Dingdong-Inc/FreshRetailNet-50K

[17] Dingdong-Inc, "frn-50k-baseline," GitHub repository, 2025. [Online]. Available: https://github.com/Dingdong-Inc/frn-50k-baseline