ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH
TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN
KHOA HỆ THỐNG THÔNG TIN

BÁO CÁO ĐỀ XUẤT ĐỀ TÀI
Môn học: HỌC SÂU VÀ ỨNG DỤNG TRONG KINH DOANH

DỰ BÁO NHU CẦU HÀNG TƯƠI SỐNG THEO NGÀY TRÊN FRESHRETAILNET-50K

bằng mạng LSTM

Lớp:	IS6109.11.CH
Giảng viên:	TS. Tạ Hoàng Thắng
Nhóm thực hiện:	Nguyễn Lý Trường Sơn – MSSV: 26848192 Tạ Nhật Hưng – MSSV: 240201038 Nguyễn Vũ Mai Phương – MSSV: 26848176 Đoàn Phạm Thanh Luân – MSSV: 26848119
Ngày nộp:	[date]

TP. HỒ CHÍ MINH — THÁNG 10 NĂM 2026

MỤC LỤC

1. TÊN ĐỀ TÀI **4**
2. TÓM TẮT **4**
3. GIỚI THIỆU **4**
3.1. Bối cảnh 4
3.2. Tầm quan trọng của bài toán 5
3.3. Vì sao chọn học sâu và LSTM 5
3.4. Động lực 5
3.5. Mục tiêu 5
3.6. Câu hỏi nghiên cứu 6
4. TỔNG QUAN NGHIÊN CỨU **6**
4.1. Phương pháp học máy truyền thống 6
4.2. Phương pháp học sâu 6
4.3. Nhu cầu bị kiểm duyệt khi hết hàng 7
4.4. Bộ dữ liệu và độ đo phổ biến 7
4.5. Ưu điểm, hạn chế và khoảng trống 7
5. ĐỊNH NGHĨA BÀI TOÁN **8**
6. DỮ LIỆU **8**
6.1. Thông tin chung 8
6.2. Các trường dữ liệu và kiểu dữ liệu 9
6.3. Khám phá dữ liệu 10
6.4. Chia dữ liệu theo thời gian 11
6.5. Tiền xử lý 11
6.6. Đặc trưng và cửa sổ cho LSTM 12
7. PHƯƠNG PHÁP VÀ KẾ HOẠCH THỰC NGHIỆM **12**
7.1. Lựa chọn phương pháp 12
7.2. Kiến trúc và huấn luyện 12
7.3. Quy trình tổng thể 13
7.4. Thiết kế thực nghiệm 13
7.5. Độ đo và notebook 13
8. KẾT QUẢ KỲ VỌNG VÀ KẾT QUẢ SƠ BỘ **14**
8.1. Kết quả kỳ vọng (giả thuyết) 14
8.2. Kết quả chính 14
8.3. Phân tích theo tầm dự báo và khuyến mãi 14
8.4. Đối chiếu giả thuyết 15
9. ĐÓNG GÓP, HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN **15**
9.1. Đóng góp 15
9.2. Hạn chế và rủi ro 16
9.3. Hướng phát triển và kết luận 16
TÀI LIỆU THAM KHẢO **16**

DANH MỤC BẢNG

Bảng 1: Câu hỏi nghiên cứu và thí nghiệm trả lời.....6
Bảng 2: So sánh các nghiên cứu liên quan.....7
Bảng 3: Đặc tả bài toán.....8
Bảng 4: Thông tin chung về FreshRetailNet-50K.....8
Bảng 5: Các trường dữ liệu sử dụng.....9
Bảng 6: Kế hoạch chia dữ liệu.....11
Bảng 7: Đặc trưng đầu vào.....12
Bảng 8: Cấu hình mô hình LSTM.....12
Bảng 9: Thiết kế thực nghiệm.....13
Bảng 10: Kết quả trên 7 ngày kiểm tra.....14
Bảng 11: WAPE theo tầm dự báo và theo khuyến mãi.....14

DANH MỤC HÌNH

Hình 1: Phân bố log(1 + doanh số), tổng doanh số theo ngày với ranh giới validation và kiểm tra, doanh số trung bình theo thứ.....10
Hình 2: Doanh số trung bình theo số giờ hết hàng, activity_flag, nhiệt độ và nhóm quản lý (ngày huấn luyện).....10
Hình 3: Quy trình từ dữ liệu đến đánh giá.....13
Hình 4: WAPE theo tầm dự báo và tổng doanh số 1,000 chuỗi: thực tế, E1 và E2.....15

1. TÊN ĐỀ TÀI

Dự báo nhu cầu hàng tươi sống theo ngày trên FreshRetailNet-50K bằng mạng LSTM (Daily Fresh-Food Demand Forecasting on FreshRetailNet-50K with LSTM Networks).

Đề tài dự báo nhu cầu 7 ngày tới của từng sản phẩm tươi sống tại từng cửa hàng bằng một mạng LSTM toàn cục; Seasonal Naive 7 ngày chỉ là mốc tham chiếu không học.

2. TÓM TẮT

Hàng tươi sống có hạn dùng ngắn, nên sai số dự báo nhu cầu dẫn trực tiếp đến hết hàng hoặc hao hụt. Đề tài xây dựng một mô hình học sâu LSTM toàn cục dự báo nhu cầu 7 ngày tới cho từng sản phẩm tại từng cửa hàng. Mô hình đọc cửa sổ 28 ngày doanh số, lịch, khuyến mãi và thời tiết, kết hợp biến biết trước của 7 ngày tới và xuất đồng thời 7 giá trị. Dữ liệu là FreshRetailNet-50K của Dingdong (CC BY 4.0); nhóm dùng một tập con cố định 1,000 chuỗi cửa hàng × sản phẩm lấy mẫu phân tầng, ở mức ngày (97,000 chuỗi – ngày). Dữ liệu được chia theo thời gian thành 83 ngày huấn luyện, 7 ngày validation và 7 ngày kiểm tra. Các ngày hết hàng hơn 8 trong 16 giờ (6:00–22:00) bị loại khỏi hàm mất mát vì doanh số bị cắt. Ba thí nghiệm chính: Seasonal Naive làm mốc tham chiếu, LSTM đầy đủ đặc trưng và LSTM bỏ khuyến mãi và thời tiết. Trong lần chạy sơ bộ, LSTM đạt WAPE 0.325 so với 0.386 của Seasonal Naive, tức giảm 15.8%; bỏ khuyến mãi và thời tiết làm WAPE tăng lên 0.348, rõ nhất ở ngày có khuyến mãi. Đóng góp: một quy trình học sâu gọn, tái lập được trên CPU, có in dữ liệu trước và sau từng bước xử lý.

3. GIỚI THIỆU

3.1. Bối cảnh

Rau, thịt, thủy sản, trái cây có hạn dùng tính bằng ngày; cửa hàng phải đặt hàng hằng ngày cho nhiều sản phẩm. Dữ liệu bán chỉ phản ánh nhu cầu khi còn hàng: khi kệ trống, phần nhu cầu còn lại không được quan sát [1]. FreshRetailNet-50K cung cấp doanh số theo ngày kèm số giờ hết hàng, đủ để nhận diện các ngày mà doanh số bị cắt [2].

3.2. Tầm quan trọng của bài toán

Dự báo thấp gây hết hàng và mất doanh thu; dự báo cao gây hao hụt vì hàng tươi sống không thể bán ở kỳ sau [3]. Khuyến mãi làm nhu cầu biến động mạnh và là một thách thức lớn của dự báo bán lẻ [4].

3.3. Vì sao chọn học sâu và LSTM

- Mô hình toàn cục: một mạng LSTM học chung trên nhiều chuỗi, chia sẻ thông tin giữa các sản phẩm và cửa hàng; cách tiếp cận này đã cho kết quả tốt với dữ liệu bán lẻ [5], [6].
- Học trực tiếp từ chuỗi: LSTM dùng ô nhớ và các cổng để học phụ thuộc theo thời gian [7], nên đọc được chu kỳ tuần và phản ứng sau khuyến mãi từ cửa sổ quá khứ mà không cần tạo thủ công các đặc trưng trễ.
- Dự báo đa đầu ra: mạng xuất đồng thời 7 giá trị cho 7 ngày tới, không đệ quy, nên sai số không tích lũy theo tầm dự báo.
- Biến biết trước: lịch, khuyến mãi và thời tiết của 7 ngày tới đi vào một nhánh riêng, giống cách các mô hình học sâu hiện đại xử lý biến tương lai đã biết [8].
- Quy mô phù hợp: chuỗi chỉ dài 97 ngày, nên một LSTM một lớp với khoảng 42,500 tham số là đủ và huấn luyện nhanh trên CPU.

3.4. Động lực

Bài báo gốc của FreshRetailNet-50K đánh giá SSA, TFT và DLinear [2]; còn thiếu một mô hình học sâu dạng chuỗi gọn, dễ tái lập trong khuôn khổ bài tập, cho biết đóng góp của khuyến mãi và thời tiết.

3.5. Mục tiêu

Mục tiêu tổng quát: xây dựng và đánh giá mô hình LSTM dự báo nhu cầu hàng tươi sống theo ngày trên FreshRetailNet-50K.

Mục tiêu cụ thể:

- Chuẩn bị tập con 1,000 chuỗi ở mức ngày; khám phá dữ liệu; xử lý giá trị không hợp lệ, ngày hết hàng nặng và ngoại lai.
- Xây dựng LSTM toàn cục cho tầm dự báo 7 ngày; so với Seasonal Naive 7 ngày.
- Đo đóng góp của nhóm đặc trưng khuyến mãi và thời tiết.
- Cung cấp notebook tái lập, in dữ liệu trước và sau từng bước xử lý.

3.6. Câu hỏi nghiên cứu

Bảng 1: *Câu hỏi nghiên cứu và thí nghiệm trả lời*

Mã	Câu hỏi nghiên cứu	Thí nghiệm trả lời (mục 7.4)
RQ1	LSTM có dự báo nhu cầu 7 ngày chính xác hơn Seasonal Naive 7 ngày không, và hơn bao nhiêu?	E2 so với E1
RQ2	Khuyến mãi và thời tiết đóng góp bao nhiêu vào độ chính xác của LSTM?	E2 so với E3

4. TỔNG QUAN NGHIÊN CỨU

4.1. Phương pháp học máy truyền thống

Fildes và cộng sự [4] tổng quan dự báo bán lẻ: dữ liệu chi tiết ở cấp sản phẩm cho phép gộp dữ liệu giữa các chuỗi (pooling), và khuyến mãi là một thách thức lớn. LightGBM [9] là bản cài đặt gradient boosting dùng lấy mẫu một phía theo gradient (GOSS) và gộp đặc trưng loại trừ (EFB). Trong cuộc thi M5 trên dữ liệu Walmart, mọi phương pháp top 50 là học máy và phần lớn dựa trên LightGBM [10]. Các mô hình này cần đặc trưng tạo thủ công (giá trị trễ, trung bình trượt) và mỗi tầm dự báo cần được thiết kế riêng để tránh rò rỉ thông tin.

4.2. Phương pháp học sâu

LSTM [7] bổ sung ô nhớ và các cổng để khắc phục hiện tượng tiêu biến gradient của RNN, cho phép học phụ thuộc với độ trễ dài. Salinas và cộng sự [6] đề xuất DeepAR, mạng hồi quy tự hồi quy huấn luyện trên nhiều chuỗi liên quan để dự báo xác suất, cho dự báo chính xác hơn các phương pháp hiện đại trên nhiều bộ dữ liệu thực. Bandara và cộng sự [5] huấn luyện LSTM toàn cục trên chuỗi doanh số của Walmart.com, khai thác thông tin giữa các chuỗi trong phân cấp sản phẩm, đạt kết quả cạnh tranh ở mức ngành hàng và mức siêu bộ phận. Lim và cộng sự [8] đề xuất Temporal Fusion Transformer (TFT), kết hợp lớp hồi quy và self-attention, xử lý biến tĩnh và biến biết trước trong tương lai, có khả năng diễn giải. Với hàng tươi sống, Miguéis và cộng sự [3] dự báo nhu cầu cá tươi hằng ngày cho một cửa hàng, có xét nhu cầu bị kiểm duyệt; LSTM nhìn chung tốt nhất so với mạng truyền thẳng, SVR, Random Forest và Holt-Winters. Trong M5, đội hạng ba dùng tổ hợp 43 mạng nơ-ron nhiều lớp LSTM theo kiểu DeepAR; ở mức sản phẩm × cửa hàng, tổ hợp này đạt WRMSSE 0.875, thấp hơn đội thắng (0.884) [10].

4.3. Nhu cầu bị kiểm duyệt khi hết hàng

Conlon và Mortimer [1] cho thấy bỏ qua thay đổi về tính sẵn có của hàng làm lệch ước lượng nhu cầu. Wang và cộng sự [2] khôi phục nhu cầu theo giờ rồi dự báo 7 ngày; với TFT, WAPE giảm từ 31.75% (doanh số thô) xuống 29.02% (nhu cầu khôi phục bằng TimesNet). Đề tài dùng cách đơn giản hơn: loại ngày hết hàng nặng khỏi hàm mất mát.

4.4. Bộ dữ liệu và độ đo phổ biến

Dữ liệu thường dùng gồm M5 của Walmart (30,490 chuỗi sản phẩm × cửa hàng, 42,840 chuỗi khi tính cả các mức tổng hợp) [10], dữ liệu Walmart.com [5], ba bộ công khai parts, electricity, traffic và hai bộ thương mại điện tử của Amazon [6], và dữ liệu riêng của một nhà bán lẻ [3]. FreshRetailNet-50K khác các bộ trên ở chỗ có nhãn hết hàng theo giờ [2], [11]. Về độ đo, M5 dùng WRMSSE [10]; Miguéis và cộng sự dùng RMSE, MAE và MPE [3]; bài báo FreshRetailNet-50K dùng WAPE và WPE [2]. WAPE chia tổng sai số tuyệt đối cho tổng doanh số, nên không phụ thuộc thang đo và tính được khi có ngày doanh số bằng 0; vì vậy đề tài chọn WAPE làm độ đo chính, kèm MAE và RMSE.

4.5. Ưu điểm, hạn chế và khoảng trống

Mô hình cây như LightGBM mạnh trên dữ liệu bảng và dẫn đầu M5 [10], nhưng phụ thuộc đặc trưng tạo thủ công. Mô hình học sâu toàn cục học trực tiếp từ chuỗi và xử lý tự nhiên dự báo đa tầm và biến biết trước [6], [8], nhưng cần nhiều chuỗi liên quan và nhạy với khởi tạo. Khoảng trống: trên FreshRetailNet-50K chưa có đánh giá một LSTM toàn cục gọn ở mức ngày, và chưa đo đóng góp của khuyến mãi và thời tiết cho mô hình học sâu. Bảng 2 tóm tắt các nghiên cứu chính.

Bảng 2: *So sánh các nghiên cứu liên quan*

Nghiên cứu	Dữ liệu	Phương pháp	Độ đo	Ưu điểm / hạn chế
Fildes et al. (2022) [4]	Tổng quan dự báo bán lẻ	Thống kê, học máy	–	Hệ thống hóa thực tiễn; không thực nghiệm mới
Makridakis et al. (2022) [10]	M5: 42,840 chuỗi Walmart	LightGBM, thống kê, học sâu	WRMSSE	LightGBM dẫn đầu; không xét hết hàng
Salinas et al. (2020) [6]	parts, electricity, traffic; thương mại điện tử Amazon	DeepAR (RNN tự hồi quy, toàn cục)	Độ chính xác dự báo xác suất	Chính xác hơn các phương pháp hiện đại; cần nhiều chuỗi liên quan
Bandara et al. (2019) [5]	Walmart.com, phân cấp sản phẩm	LSTM toàn cục + nhóm sản phẩm	Sai số dự báo	Khai thác thông tin giữa chuỗi; dữ liệu thương mại điện tử

Nghiên cứu	Dữ liệu	Phương pháp	Độ đo	Ưu điểm / hạn chế
Lim et al. (2021) [8]	Nhiều bộ dữ liệu thực	TFT (attention, đa tầm)	Sai số đa tầm dự báo	Diễn giải được; phức tạp, tốn tài nguyên
Miguéis et al. (2022) [3]	Cá tươi, một cửa hàng	LSTM, FNN, SVR, RF, Holt-Winters	RMSE, MAE, MPE	Có xét kiểm duyệt; một cửa hàng, dữ liệu riêng
Conlon & Mortimer (2013) [1]	Máy bán hàng tự động, trạng thái 4 giờ	Ước lượng nhu cầu kinh tế lượng	Độ lệch ước lượng	Chứng minh lệch do hết hàng; không phải dự báo
Wang et al. (2025) [2]	FreshRetailNet-50K	Khôi phục nhu cầu + SSA, TFT, DLinear	WAPE, WPE	Nhãn hết hàng theo giờ; mô hình nặng

5. ĐỊNH NGHĨA BÀI TOÁN

Ký hiệu: i là chuỗi cửa hàng × sản phẩm, t là ngày; y(i,t) là doanh số ngày (sale_amount), c(i,t) là số giờ hết hàng từ 6:00 đến 22:00 (stock_hour6_22_cnt, 0–16); T là mốc dự báo (ngày quan sát cuối).

Bảng 3: *Đặc tả bài toán*

Thành phần	Mô tả
Bài toán kinh doanh	Ước lượng nhu cầu 7 ngày tới để quyết định lượng đặt hàng hằng ngày cho hàng tươi sống
Đầu vào	Cửa sổ 28 ngày đến mốc T: doanh số, thứ trong tuần, holiday_flag, discount, activity_flag, bốn biến thời tiết; biến biết trước của 7 ngày T+1 … T+7
Đầu ra	ŷ(i,T+1) … ŷ(i,T+7): vector 7 giá trị doanh số ngày
Loại tác vụ	Hồi quy có giám sát trên chuỗi thời gian, nhiều đầu ra; mô hình toàn cục học chung 1,000 chuỗi
Mục tiêu	Cực tiểu sai số bình phương trên ngày không bị loại (huấn luyện); WAPE thấp nhất trên 7 ngày kiểm tra 26/06–02/07/2024
Tiêu chí thành công	LSTM vượt Seasonal Naive về WAPE, MAE và RMSE

6. DỮ LIỆU

6.1. Thông tin chung

Bảng 4: *Thông tin chung về FreshRetailNet-50K*

Thuộc tính	Giá trị
Tên, đơn vị phát hành	FreshRetailNet-50K; Dingdong (Trung Quốc), 2025 [2], [11]
Liên kết	https://huggingface.co/datasets/Dingdong-Inc/FreshRetailNet-50K
Giấy phép	CC BY 4.0 [11]

Thuộc tính	Giá trị
Quy mô gốc	50,000 chuỗi cửa hàng × sản phẩm; 898 cửa hàng; 18 thành phố; 865 product_id
Thời gian	train: 28/03/2024 – 25/06/2024 (90 ngày); eval: 26/06/2024 – 02/07/2024 (7 ngày)
Số dòng gốc	train 4,500,000 = 50,000 × 90; eval 350,000 = 50,000 × 7
Tập con dùng trong đề tài	1,000 chuỗi × 97 ngày = 97,000 chuỗi – ngày
Số mẫu cho LSTM	49,000 cửa sổ huấn luyện; 1,000 validation; 1,000 kiểm tra; 56,000 khi huấn luyện lại trên 90 ngày
Số đặc trưng đầu vào	9 biến gốc theo ngày; sau mã hóa: 15 biến mỗi bước quá khứ, 14 biến biết trước mỗi ngày tương lai
Biến mục tiêu	sale_amount: doanh số ngày, số thực không âm, đã chuẩn hóa bởi đơn vị phát hành
Giá trị thiếu	Không có ở mọi cột (train và eval)

6.2. Các trường dữ liệu và kiểu dữ liệu

Đề tài chỉ dùng dữ liệu theo ngày; hai mảng 24 giờ (hours_sale, hours_stock_status) không được sử dụng. Đây là bài toán hồi quy nên không có phân bố lớp.

Bảng 5: *Các trường dữ liệu sử dụng*

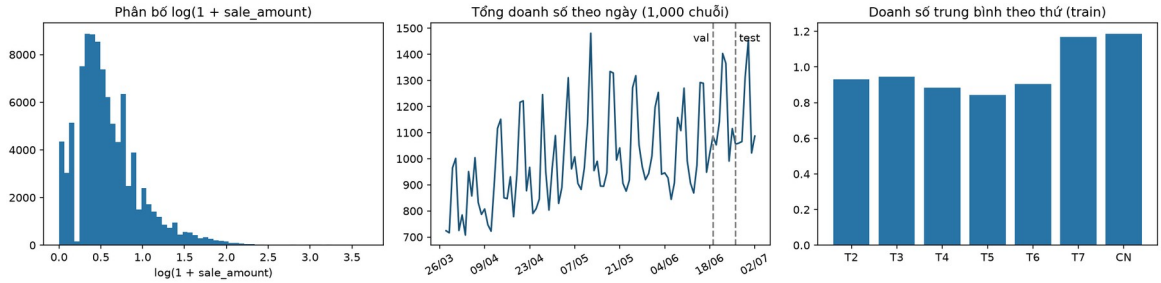
Nhóm	Trường	Kiểu	Cách dùng
Định danh	store_id, product_id, management_group_id	Số nguyên	Xác định chuỗi; phân tầng khi lấy tập con
Thời gian	dt	Chuỗi ngày	Chia dữ liệu; sinh thứ trong tuần
Mục tiêu	sale_amount	Số thực ≥ 0	Doanh số ngày; đầu vào và mục tiêu
Hết hàng	stock_hour6_22_cnt	Số nguyên 0–16	Xác định ngày bị loại khỏi hàm mất mát
Khuyến mãi	discount, activity_flag	Số thực, 0/1	Tỷ lệ giá (1.0 = không giảm); cờ khuyến mãi
Lịch	holiday_flag	0/1	Bằng 1 vào cuối tuần và ngày lễ
Thời tiết	precpt, avg_temperature, avg_humidity, avg_wind_level	Số thực	Mưa, nhiệt độ, độ ẩm, sức gió

Tập con gồm 1,000 chuỗi, lấy mẫu phân tầng theo nhóm quản lý (7 nhóm) và mức hết hàng của chuỗi (ba nhóm theo tỷ lệ giờ hết hàng trên tập train), phân bổ theo tỷ lệ với seed 42. Tỷ lệ giờ hết hàng trung bình của tập con là 0.201, so với 0.199 của toàn bộ dữ liệu.

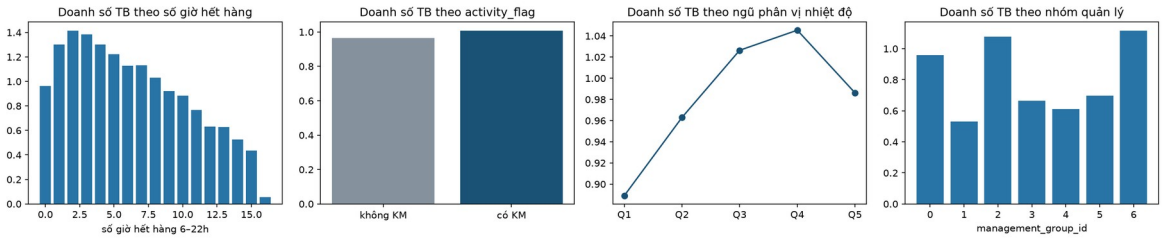
6.3. Khám phá dữ liệu

Số liệu dưới đây tính trên tập con với doanh số gốc: phân bố tính trên cả 97 ngày, các phân tích theo yếu tố tính trên 83 ngày huấn luyện.

- Phân bố: sale_amount lệch phải mạnh (độ lệch 8.71); trung vị 0.7, phân vị 99 là 5.8, lớn nhất 39.0; 4.46% chuỗi – ngày có doanh số bằng 0.
- Chu kỳ tuần: doanh số trung bình thứ Bảy 1.170 và Chủ nhật 1.187, cao hơn 1.41 lần so với ngày thấp nhất (thứ Năm, 0.843). holiday_flag bằng 1 ở 100% ngày thứ Bảy và 92.9% ngày Chủ nhật, nên trùng phần lớn với cuối tuần.
- Hết hàng: 55.6% ngày không có giờ hết hàng; 4.17% ngày hết hàng cả 16 giờ, với doanh số trung bình chỉ 0.055. Từ 2 giờ hết hàng trở lên, doanh số trung bình giảm dần theo số giờ hết hàng (1.415 ở 2 giờ, 0.436 ở 15 giờ).
- Khuyến mãi: ngày có activity_flag = 1 có doanh số trung bình 1.008, so với 0.965; ngày có discount ≤ 0.70 có doanh số trung bình 2.049, so với 0.820 khi không giảm giá.
- Thời tiết: tương quan hạng Spearman với doanh số đều nhỏ (lượng mưa −0.013, nhiệt độ 0.043, độ ẩm −0.033, sức gió −0.031). precpt dương ở 82,840 trong 83,000 chuỗi – ngày huấn luyện, nên phép chia có mưa và không mưa không mang nhiều thông tin.
- Nhóm quản lý: doanh số trung bình từ 0.532 (nhóm 1, 21 chuỗi) đến 1.117 (nhóm 6, 528 chuỗi); nhóm 0 có tỷ lệ ngày bằng 0 cao nhất (13.0%).



Hình 1: *Phân bố log(1 + doanh số), tổng doanh số theo ngày với ranh giới validation và kiểm tra, doanh số trung bình theo thứ*



Hình 2: *Doanh số trung bình theo số giờ hết hàng, activity_flag, nhiệt độ và nhóm quản lý (ngày huấn luyện)*

6.4. Chia dữ liệu theo thời gian

Bảng 6: *Kế hoạch chia dữ liệu*

Tập	Khoảng thời gian	Số ngày	Chuỗi – ngày	Mục đích
Huấn luyện	28/03/2024 – 18/06/2024	83	83,000	Huấn luyện
Validation	19/06/2024 – 25/06/2024	7	7,000	Early stopping, chọn số epoch
Kiểm tra	26/06/2024 – 02/07/2024 (tập eval)	7	7,000	Đánh giá cuối

Mốc dự báo cho tập kiểm tra là 25/06/2024; không dùng thông tin sau mốc này, trừ các biến biết trước.

6.5. Tiền xử lý

- Giá trị thiếu: không có ở mọi cột, nhưng discount = 0 là không hợp lệ với định nghĩa tỷ lệ giá (0.36% dòng của toàn bộ tập train; 283 dòng trong tập con). Các giá trị này được coi là thiếu và điền bằng trung vị của sản phẩm cùng trạng thái activity_flag trên ngày huấn luyện; giá trị lớn hơn 1 được cắt về 1 (tập con không có).
- Hết hàng: khi sản phẩm hết hàng trong một phần của ngày, doanh số ghi nhận chỉ là cận dưới của nhu cầu thật (nhu cầu bị kiểm duyệt) [1]. Huấn luyện trực tiếp trên doanh số này khiến mô hình học mức nhu cầu thấp hơn thực tế [2]. Chuỗi – ngày có c(i,t) > 8 bị loại khỏi hàm mất mát và khỏi đánh giá chính, nhưng vẫn được dùng làm đầu vào. Tỷ lệ bị loại là 15.46% ở tập huấn luyện (12,830 chuỗi – ngày), 13.51% ở validation và 13.84% ở kiểm tra; doanh số trung bình của ngày bị loại là 0.577, so với 1.085 của ngày giữ lại.
- Ngoại lai: doanh số đầu vào của LSTM được chặn trên theo phân vị 99 của từng chuỗi, tính trên 83 ngày huấn luyện; mục tiêu và giá trị dùng để đánh giá giữ nguyên. Lý do: đỉnh nhu cầu là tín hiệu thật nên không xóa, nhưng một giá trị cực lớn trong cửa sổ đầu vào có thể chi phối trạng thái ẩn và hệ số chuẩn hóa của chuỗi. Có 791 trong 83,000 giá trị ngày huấn luyện bị chặn (0.95%); giá trị lớn nhất của đầu vào giảm từ 39.0 xuống 27.9.
- Chuẩn hóa: doanh số chia cho trung bình của chuỗi trên ngày huấn luyện (sau khi chặn), để mô hình toàn cục học được trên các chuỗi có quy mô khác nhau; dự báo được nhân lại để về đơn vị gốc. Bốn biến thời tiết chuẩn hóa z-score bằng trung bình và độ lệch chuẩn của ngày huấn luyện. discount nằm trong [0, 1] nên giữ nguyên.

6.6. Đặc trưng và cửa sổ cho LSTM

Bảng 7: *Đặc trưng đầu vào*

Đặc trưng	Mã hóa	Số cột	Dùng ở
Doanh số	Chia trung bình chuỗi	1	Quá khứ
Thứ trong tuần	One-hot	7	Quá khứ, tương lai
holiday_flag	0/1	1	Quá khứ, tương lai
discount, activity_flag	Giữ nguyên	2	Quá khứ, tương lai (bỏ ở E3)
Thời tiết	z-score	4	Quá khứ, tương lai (bỏ ở E3)

Mỗi mẫu gồm cửa sổ 28 ngày đến mốc T (28 × 15), biến biết trước của 7 ngày T+1 … T+7 (7 × 14), và mục tiêu là doanh số đã chuẩn hóa của 7 ngày đó kèm mặt nạ cho ngày bị loại. Mốc huấn luyện trượt từng ngày, cho 49 mẫu mỗi chuỗi; 46,604 trong 343,000 ô mục tiêu bị che. Mẫu validation có mốc T = 18/06/2024 (dự báo 19/06–25/06), mẫu kiểm tra có mốc T = 25/06/2024 (dự báo 26/06–02/07); mỗi chuỗi có một mẫu validation và một mẫu kiểm tra. Khi huấn luyện lại trên 90 ngày, mốc trượt đến 18/06/2024, cho 56 mẫu mỗi chuỗi. Ở E3, mỗi bước quá khứ còn 9 biến và mỗi ngày tương lai còn 8 biến.

7. PHƯƠNG PHÁP VÀ KẾ HOẠCH THỰC NGHIỆM

7.1. Lựa chọn phương pháp

Mô hình chính là LSTM toàn cục, vì các lý do nêu ở mục 3.3 [7], [5]. Seasonal Naive 7 ngày, $\hat{y}(i,t) = y(i,t-7)$ với tuần cuối trước mốc dự báo được lặp lại, là mốc tham chiếu không học mà mô hình học phải vượt qua.

7.2. Kiến trúc và huấn luyện

Bảng 8: *Cấu hình mô hình LSTM*

Thành phần	Cấu hình
Bộ mã hóa	Một lớp LSTM, 64 đơn vị ẩn, đọc cửa sổ 28 ngày
Đầu ra	Trạng thái ẩn cuối ghép với biến biết trước của 7 ngày (7 × 14), qua lớp kết nối đầy đủ 128 đơn vị (ReLU), ra 7 giá trị
Số tham số	42,503 (E2); 35,591 (E3)
Hàm mất mát	MSE trên doanh số đã chuẩn hóa, có mặt nạ cho ngày bị loại
Tối ưu	Adam, tốc độ học 0.001, batch 256, tối đa 30 epoch
Early stopping	Theo WAPE validation, kiên nhẫn 4 epoch; sau đó huấn luyện lại trên 90 ngày với số epoch tốt nhất
Tái lập	Seed 42; PyTorch một luồng CPU, thuật toán tất định

7.3. Quy trình tổng thể



Hình 3: *Quy trình từ dữ liệu đến đánh giá*

7.4. Thiết kế thực nghiệm

Bảng 9: *Thiết kế thực nghiệm*

Thí nghiệm	Mô hình	Đầu vào	Mục đích
E1	Seasonal Naive 7 ngày	y(i,t−7)	Mốc tham chiếu không học
E2	LSTM	Đầy đủ (Bảng 7)	Mô hình chính (RQ1)
E3	LSTM	Như E2, bỏ discount, activity_flag và thời tiết	Đóng góp của khuyến mãi và thời tiết (RQ2)
E4 (phụ)	LSTM	Như E2, không loại ngày hết hàng khỏi hàm mất mát	Kiểm tra quy tắc hết hàng

E2 so với E1 trả lời RQ1; E2 so với E3 trả lời RQ2. E4 rẻ (khoảng 30 giây) nên được chạy thêm để xem quy tắc loại ngày hết hàng có tác dụng không. Mọi thí nghiệm dùng cùng tập con, cùng cách chia và cùng độ đo.

7.5. Độ đo và notebook

Với y là doanh số thực, ŷ là dự báo, tổng lấy trên n chuỗi – ngày được đánh giá:

- WAPE = Σ|y − ŷ| / Σy: độ đo chính; không phụ thuộc thang đo, tính được khi có ngày doanh số bằng 0.
- MAE = (1/n) Σ|y − ŷ|: sai số trung bình theo đơn vị chuẩn hóa của dữ liệu.
- RMSE = √[(1/n) Σ(y − ŷ)²]: phạt nặng sai số lớn, nhạy với đỉnh nhu cầu.

Đánh giá chính dùng các chuỗi – ngày kiểm tra có c(i,t) ≤ 8 (6,031 trong 7,000), theo cùng quy tắc với tập huấn luyện; kết quả trên toàn bộ 7,000 chuỗi – ngày được

báo cáo kèm. WAPE được tách theo tầm dự báo h = 1…7 và theo ngày có hoặc không có khuyến mãi.

Notebook FreshRetailNet_LSTM.ipynb in dữ liệu trước và sau từng bước xử lý (tải dữ liệu, chọn tập con, bảng theo ngày, EDA, sửa discount, hết hàng, ngoại lai, đặc trưng, chuẩn hóa, cửa sổ). Trên CPU với PyTorch một luồng, notebook chạy khoảng 90 giây khi dữ liệu đã có trong bộ nhớ đệm; hai lần chạy cho kết quả giống hệt.

8. KẾT QUẢ KỲ VỌNG VÀ KẾT QUẢ SƠ BỘ

8.1. Kết quả kỳ vọng (giả thuyết)

Trước khi chạy, nhóm đặt các giả thuyết sau:

- H1 (RQ1): LSTM có WAPE, MAE và RMSE thấp hơn Seasonal Naive 7 ngày.
- H2 (RQ2): bỏ khuyến mãi và thời tiết (E3) làm tăng WAPE so với E2, rõ nhất ở ngày có khuyến mãi.

8.2. Kết quả chính

Bảng 10: *Kết quả trên 7 ngày kiểm tra*

Thí nghiệm	WAPE	MAE	RMSE	WAPE giảm so với E1	WAPE (toàn bộ ngày)
E1 Seasonal Naive	0.3859	0.4780	0.7893	–	0.4306
E2 LSTM đầy đủ	0.3248	0.4023	0.6553	15.8%	0.3782
E3 LSTM bỏ khuyến mãi, thời tiết	0.3476	0.4306	0.7768	9.9%	0.3965
E4 LSTM không loại ngày hết hàng (phụ)	0.3243	0.4017	0.6940	16.0%	0.3737

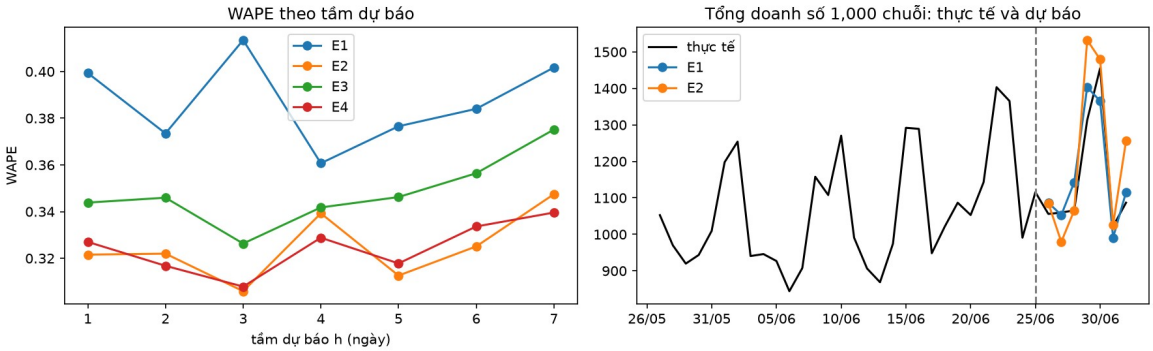
Kết quả sơ bộ của một lần chạy (seed 42). Ba cột độ đo đầu tính trên 6,031 chuỗi – ngày có c(i,t) ≤ 8; cột cuối tính trên toàn bộ 7,000 chuỗi – ngày. Số epoch tốt nhất: 3 (E2), 2 (E3), 3 (E4).

8.3. Phân tích theo tầm dự báo và khuyến mãi

Bảng 11: *WAPE theo tầm dự báo và theo khuyến mãi*

Nhóm	E1	E2	E3	E4
h = 1	0.3993	0.3216	0.3439	0.3270
h = 2	0.3735	0.3220	0.3459	0.3168
h = 3	0.4135	0.3059	0.3263	0.3079
h = 4	0.3607	0.3393	0.3418	0.3288

Nhóm	E1	E2	E3	E4
h = 5	0.3765	0.3126	0.3462	0.3178
h = 6	0.3840	0.3251	0.3564	0.3336
h = 7	0.4017	0.3475	0.3751	0.3396
Ngày có khuyến mãi (1,966)	0.3823	0.3078	0.3479	0.3115
Ngày không khuyến mãi (4,065)	0.3876	0.3328	0.3474	0.3303



Hình 4: *WAPE theo tầm dự báo và tổng doanh số 1,000 chuỗi: thực tế, E1 và E2*

8.4. Đối chiếu giả thuyết

- H1 được ủng hộ: E2 thấp hơn E1 ở cả ba độ đo (WAPE 0.3248 so với 0.3859, giảm 15.8%; MAE 0.4023 so với 0.4780; RMSE 0.6553 so với 0.7893) và ở cả 7 tầm dự báo.
- H2 được ủng hộ: bỏ khuyến mãi và thời tiết làm WAPE tăng từ 0.3248 lên 0.3476. Mức tăng tập trung ở ngày có khuyến mãi (0.3078 lên 0.3479), còn ở ngày không khuyến mãi chỉ tăng từ 0.3328 lên 0.3474. Vì E3 bỏ cả hai nhóm cùng lúc, kết quả này chưa tách được phần của khuyến mãi và phần của thời tiết; EDA cho thấy thời tiết có tương quan rất yếu với doanh số (mục 6.3).
- E4: không loại ngày hết hàng cho WAPE gần như bằng E2 (0.3243 so với 0.3248) nhưng RMSE cao hơn (0.6940 so với 0.6553); quy tắc hết hàng chưa cải thiện WAPE trong lần chạy này.
- Chỉ có một seed và một tuần kiểm tra, nên chênh lệch WAPE dưới khoảng 0.01 (như E2 và E4) chưa đủ để kết luận.

9. ĐÓNG GÓP, HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN

9.1. Đóng góp

Đề tài đóng góp một LSTM toàn cục gọn cho dự báo nhu cầu hàng tươi sống theo ngày trên dữ liệu công khai, giảm WAPE 15.8% so với Seasonal Naive trong

lần chạy sơ bộ; một phép đo đóng góp chung của khuyến mãi và thời tiết cho mô hình học sâu; và một notebook tái lập, chạy khoảng 90 giây trên CPU.

9.2. Hạn chế và rủi ro

- Một seed và một tuần kiểm tra: cần lặp nhiều seed và thêm các mốc kiểm tra trượt.
- Ngày hết hàng một phần vẫn bị kiểm duyệt: có thể khôi phục nhu cầu theo giờ ở giai đoạn sau.
- Thời tiết tương lai được giả định là đã biết, như trong bài báo gốc [2].
- Tập con chỉ có 1,000 chuỗi; cần mở rộng khi có thêm tài nguyên.

9.3. Hướng phát triển và kết luận

Giai đoạn sau: tách riêng đóng góp của khuyến mãi và của thời tiết; lặp nhiều seed; khôi phục nhu cầu theo giờ; chạy trên 50,000 chuỗi; so sánh với LightGBM và TFT; và thêm lớp quyết định tồn kho.

Kết luận: mạng LSTM toàn cục dự báo nhu cầu 7 ngày chính xác hơn Seasonal Naive trên tập con 1,000 chuỗi, và khuyến mãi cùng thời tiết giúp giảm sai số, chủ yếu ở ngày có khuyến mãi. Dự báo này có thể dùng làm đầu vào trực tiếp cho lượng đặt hàng hằng ngày của từng sản phẩm tại từng cửa hàng.

TÀI LIỆU THAM KHẢO

[1] C. T. Conlon and J. H. Mortimer, "Demand estimation under incomplete product availability," *American Economic Journal: Microeconomics*, vol. 5, no. 4, pp. 1–30, 2013, doi: 10.1257/mic.5.4.1.

[2] Y. Wang, J. Gu, L. Long, X. Li, L. Shen, Z. Fu, X. Zhou, and X. Jiang, "FreshRetailNet-50K: A stockout-annotated censored demand dataset for latent demand recovery and forecasting in fresh retail," arXiv:2505.16319, 2025. [Online]. Available: https://arxiv.org/abs/2505.16319

[3] V. L. Miguéis, A. Pereira, J. Pereira, and G. Figueira, "Reducing fresh fish waste while ensuring availability: Demand forecast using censored data and machine learning," *Journal of Cleaner Production*, vol. 359, Art. no. 131852, 2022, doi: 10.1016/j.jclepro.2022.131852.

[4] R. Fildes, S. Ma, and S. Kolassa, "Retail forecasting: Research and practice," *International Journal of Forecasting*, vol. 38, no. 4, pp. 1283–1318, 2022, doi: 10.1016/j.ijforecast.2019.06.004.

[5] K. Bandara, P. Shi, C. Bergmeir, H. Hewamalage, Q. Tran, and B. Seaman, "Sales demand forecast in e-commerce using a long short-term memory neural network methodology," in *Neural Information Processing (ICONIP 2019)*, T. Gedeon, K. W. Wong, and M. Lee, Eds., Lecture Notes in Computer Science, vol. 11955. Cham, Switzerland: Springer, 2019, pp. 462–474, doi: 10.1007/978-3-030-36718-3_39.

[6] D. Salinas, V. Flunkert, J. Gasthaus, and T. Januschowski, "DeepAR: Probabilistic forecasting with autoregressive recurrent networks," *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020, doi: 10.1016/j.ijforecast.2019.07.001.

[7] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[8] B. Lim, S. Ö. Arık, N. Loeff, and T. Pfister, "Temporal Fusion Transformers for interpretable multi-horizon time series forecasting," *International Journal of Forecasting*, vol. 37, no. 4, pp. 1748–1764, 2021, doi: 10.1016/j.ijforecast.2021.03.012.

[9] G. Ke *et al.*, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems 30*, 2017. [Online]. Available: https://proceedings.neurips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html

[10] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "M5 accuracy competition: Results, findings, and conclusions," *International Journal of Forecasting*, vol. 38, no. 4, pp. 1346–1364, 2022, doi: 10.1016/j.ijforecast.2021.11.013.

[11] Dingdong-Inc, "FreshRetailNet-50K," Hugging Face dataset card, v1.0, 2025. [Online]. Available: https://huggingface.co/datasets/Dingdong-Inc/FreshRetailNet-50K