**ĐẠI HỌC QUỐC GIA TP. HỒ CHÍ MINH**
**TRƯỜNG ĐẠI HỌC CÔNG NGHỆ THÔNG TIN**
KHOA HỆ THỐNG THÔNG TIN

**BÁO CÁO ĐỀ XUẤT ĐỀ TÀI**
**Môn học: HỌC SÂU VÀ ỨNG DỤNG TRONG KINH DOANH**

# DỰ BÁO NHU CẦU HÀNG TƯƠI SỐNG THEO NGÀY TRÊN FRESHRETAILNET-50K

## bằng mạng LSTM
## Phần 2: ablation và đánh giá độ tin cậy

| | |
|---|---|
| **Lớp:** | IS6109.11.CH |
| **Giảng viên:** | TS. Tạ Hoàng Thắng |
| **Nhóm thực hiện:** | Nguyễn Lý Trường Sơn – MSSV: 26848192 |
| | Tạ Nhật Hưng – MSSV: 240201038 |
| | Nguyễn Vũ Mai Phương – MSSV: 26848176 |
| | Đoàn Phạm Thanh Luân – MSSV: 26848119 |
| **Ngày nộp:** | [date] |

**TP. HỒ CHÍ MINH — THÁNG 10 NĂM 2026**

# MỤC LỤC

**1. TÊN ĐỀ TÀI** ..... **4**
**2. TÓM TẮT** ..... **4**
**3. GIỚI THIỆU** ..... **4**
3.1. Bối cảnh ..... 4
3.2. Tầm quan trọng của bài toán ..... 5
3.3. Vì sao chọn học sâu và LSTM ..... 5
3.4. Động lực ..... 5
3.5. Mục tiêu ..... 5
3.6. Câu hỏi nghiên cứu ..... 6
**4. TỔNG QUAN NGHIÊN CỨU** ..... **6**
4.1. Phương pháp học máy truyền thống ..... 6
4.2. Phương pháp học sâu ..... 6
4.3. Nhu cầu bị kiểm duyệt khi hết hàng ..... 7
4.4. Bộ dữ liệu và độ đo phổ biến ..... 7
4.5. Ưu điểm, hạn chế và khoảng trống ..... 8
**5. ĐỊNH NGHĨA BÀI TOÁN** ..... **8**
**6. DỮ LIỆU** ..... **9**
6.1. Thông tin chung ..... 9
6.2. Các trường dữ liệu và kiểu dữ liệu ..... 10
6.3. Khám phá dữ liệu ..... 10
6.4. Chia dữ liệu theo thời gian ..... 11
6.5. Tiền xử lý ..... 12
6.6. Đặc trưng và cửa sổ cho LSTM ..... 12
**7. PHƯƠNG PHÁP VÀ KẾ HOẠCH THỰC NGHIỆM** ..... **13**
7.1. Lựa chọn phương pháp ..... 13
7.2. Kiến trúc và huấn luyện ..... 13
7.3. Quy trình tổng thể ..... 14
7.4. Thiết kế thực nghiệm ..... 14
7.5. Độ đo và notebook ..... 15
7.6. Đánh giá trượt và kiểm định thống kê (phần 2) ..... 15
**8. KẾT QUẢ KỲ VỌNG VÀ KẾT QUẢ THỰC NGHIỆM** ..... **16**
8.1. Kết quả kỳ vọng (giả thuyết) ..... 16
8.2. Phần 1: kết quả trên một lần chia ..... 17
8.3. RQ3: đóng góp riêng của khuyến mãi và thời tiết ..... 17
8.4. RQ5: độ ổn định qua seed và tuần kiểm tra ..... 19
8.5. Đối chiếu giả thuyết ..... 20
**9. ĐÓNG GÓP, HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN** ..... **21**
9.1. Đóng góp ..... 21
9.2. Hạn chế và rủi ro ..... 21
9.3. Hướng phát triển và kết luận ..... 21

**TÀI LIỆU THAM KHẢO..... 22**

## DANH MỤC BẢNG

Bảng 1: Câu hỏi nghiên cứu và thí nghiệm trả lời.....6
Bảng 2: So sánh các nghiên cứu liên quan.....8
Bảng 3: Đặc tả bài toán.....8
Bảng 4: Thông tin chung về FreshRetailNet-50K.....9
Bảng 5: Các trường dữ liệu sử dụng.....10
Bảng 6: Kế hoạch chia dữ liệu.....11
Bảng 7: Đặc trưng đầu vào.....12
Bảng 8: Cấu hình mô hình LSTM.....13
Bảng 9: Thiết kế thực nghiệm.....14
Bảng 10: Năm tuần kiểm tra trượt.....15
Bảng 11: Kết quả trên 7 ngày kiểm tra (seed 42).....17
Bảng 12: RQ3: ablation qua 25 lần chạy.....17
Bảng 13: RQ3: sai số train, validation và test.....18
Bảng 14: RQ5: trung bình ± độ lệch chuẩn qua 5 seed × 5 tuần.....19
Bảng 15: RQ5: Wilcoxon trên MAE theo chuỗi (n = 1,000), hiệu chỉnh Holm.....19
Bảng 16: RQ5: kiểm định phụ (Diebold–Mariano và Wilcoxon theo lần chạy).....20

## DANH MỤC HÌNH

Hình 1: Phân bố log(1 + doanh số), tổng doanh số theo ngày với ranh giới validation và kiểm tra, doanh số trung bình theo thứ.....11
Hình 2: Doanh số trung bình theo số giờ hết hàng, activity_flag, nhiệt độ và nhóm quản lý (ngày huấn luyện).....11
Hình 3: Quy trình từ dữ liệu đến đánh giá.....14
Hình 4: Phần 1: WAPE theo tầm dự báo và tổng doanh số 1,000 chuỗi (thực tế, E1 và E2) .....17
Hình 5: RQ3: WAPE theo ngày có và không có khuyến mãi (trái); WAPE train, validation và test trung bình 25 lần chạy (phải).....18
Hình 6: RQ5: phân bố WAPE qua 25 lần chạy (trái) và WAPE trung bình 5 seed theo tuần kiểm tra (phải).....19

# 1. TÊN ĐỀ TÀI

**Dự báo nhu cầu hàng tươi sống theo ngày trên FreshRetailNet-50K bằng mạng LSTM** (Daily Fresh-Food Demand Forecasting on FreshRetailNet-50K with LSTM Networks).

Đề tài dự báo nhu cầu 7 ngày tới của từng sản phẩm tươi sống tại từng cửa hàng bằng một mạng LSTM toàn cục; Seasonal Naive 7 ngày chỉ là mốc tham chiếu không học. Bản này (phần 2) bổ sung ablation tách riêng khuyến mãi và thời tiết (RQ3) và đánh giá độ tin cậy qua nhiều seed, nhiều tuần kiểm tra trượt cùng kiểm định thống kê (RQ5).

# 2. TÓM TẮT

Hàng tươi sống có hạn dùng ngắn, nên sai số dự báo nhu cầu dẫn trực tiếp đến hết hàng hoặc hao hụt. Đề tài xây dựng một mạng LSTM toàn cục dự báo nhu cầu 7 ngày tới cho từng sản phẩm tại từng cửa hàng, từ cửa sổ 28 ngày doanh số, lịch, khuyến mãi, thời tiết và các biến biết trước của 7 ngày tới. Dữ liệu là FreshRetailNet-50K (CC BY 4.0); nhóm dùng tập con 1,000 chuỗi lấy mẫu phân tầng, ở mức ngày (97,000 chuỗi – ngày). Ngày hết hàng hơn 8 trong 16 giờ bị loại khỏi hàm mất mát. Phần 1 so LSTM với Seasonal Naive trên một lần chia: WAPE 0.325 so với 0.386. Phần 2 tách riêng nhóm khuyến mãi và nhóm thời tiết, và lặp mọi thí nghiệm với 5 seed trên 5 tuần kiểm tra trượt, kèm kiểm định Wilcoxon có hiệu chỉnh Holm, Diebold–Mariano và độ lớn hiệu ứng. Trung bình qua 25 lần chạy, LSTM đạt WAPE 0.339 ± 0.016 so với 0.394 ± 0.013, giảm 14.1%, tốt hơn ở cả 25 lần chạy và có ý nghĩa ở mọi kiểm định. Bỏ khuyến mãi hoặc thời tiết làm WAPE tăng khoảng 0.004–0.005; chỉ phần đóng góp của khuyến mãi có ý nghĩa ở mức chuỗi, còn thời tiết làm mô hình quá khớp nhẹ. Đóng góp: một quy trình học sâu tái lập trên CPU và một đánh giá có kiểm định thống kê.

# 3. GIỚI THIỆU

## 3.1. Bối cảnh

Rau, thịt, thủy sản, trái cây có hạn dùng tính bằng ngày; cửa hàng phải đặt hàng hằng ngày cho nhiều sản phẩm. Dữ liệu bán chỉ phản ánh nhu cầu khi còn hàng: khi kệ trống, phần nhu cầu còn lại không được quan sát [1]. FreshRetailNet-50K cung

cấp doanh số theo ngày kèm số giờ hết hàng, đủ để nhận diện các ngày mà doanh số bị cắt [2].

### 3.2. Tầm quan trọng của bài toán

Dự báo thấp gây hết hàng và mất doanh thu; dự báo cao gây hao hụt vì hàng tươi sống không thể bán ở kỳ sau [3]. Khuyến mãi làm nhu cầu biến động mạnh và là một thách thức lớn của dự báo bán lẻ [4].

### 3.3. Vì sao chọn học sâu và LSTM

- Mô hình toàn cục: một mạng LSTM học chung trên nhiều chuỗi, chia sẻ thông tin giữa các sản phẩm và cửa hàng; cách tiếp cận này đã cho kết quả tốt với dữ liệu bán lẻ [5], [6].
- Học trực tiếp từ chuỗi: LSTM dùng ô nhớ và các cổng để học phụ thuộc theo thời gian [7], nên đọc được chu kỳ tuần và phản ứng sau khuyến mãi từ cửa sổ quá khứ mà không cần tạo thủ công các đặc trưng trễ.
- Dự báo đa đầu ra: mạng xuất đồng thời 7 giá trị cho 7 ngày tới, không đệ quy, nên sai số không tích lũy theo tầm dự báo.
- Biến biết trước: lịch, khuyến mãi và thời tiết của 7 ngày tới đi vào một nhánh riêng, giống cách các mô hình học sâu hiện đại xử lý biến tương lai đã biết [8].
- Quy mô phù hợp: chuỗi chỉ dài 97 ngày, nên một LSTM một lớp với khoảng 42,500 tham số là đủ và huấn luyện nhanh trên CPU.

### 3.4. Động lực

Bài báo gốc của FreshRetailNet-50K đánh giá SSA, TFT và DLinear [2]; còn thiếu một mô hình học sâu dạng chuỗi gọn, dễ tái lập trong khuôn khổ bài tập, cho biết đóng góp của khuyến mãi và thời tiết.

### 3.5. Mục tiêu

Mục tiêu tổng quát: xây dựng và đánh giá mô hình LSTM dự báo nhu cầu hàng tươi sống theo ngày trên FreshRetailNet-50K.

Mục tiêu cụ thể:

- Chuẩn bị tập con 1,000 chuỗi ở mức ngày; khám phá dữ liệu; xử lý giá trị không hợp lệ, ngày hết hàng nặng và ngoại lai.
- Xây dựng LSTM toàn cục cho tầm dự báo 7 ngày; so với Seasonal Naive 7 ngày.

- Đo đóng góp chung và đóng góp riêng của nhóm khuyến mãi và nhóm thời tiết, kèm mức quá khớp.
- Đánh giá độ ổn định qua nhiều seed và nhiều tuần kiểm tra trượt, có kiểm định thống kê.
- Cung cấp notebook tái lập, in dữ liệu trước và sau từng bước xử lý.

### 3.6. Câu hỏi nghiên cứu

**Bảng 1:** *Câu hỏi nghiên cứu và thí nghiệm trả lời*

| Mã | Câu hỏi nghiên cứu | Thí nghiệm trả lời (mục 7.4, 7.6) |
|---|---|---|
| RQ1 | LSTM có dự báo nhu cầu 7 ngày chính xác hơn Seasonal Naive 7 ngày không, và hơn bao nhiêu? | E2 so với E1 |
| RQ2 | Khuyến mãi và thời tiết đóng góp bao nhiêu vào độ chính xác của LSTM? | E2 so với E3 |
| RQ3 | Đóng góp riêng của khuyến mãi và của thời tiết là bao nhiêu, và thời tiết có làm mô hình quá khớp không? | E2, E3a, E3b, E3; sai số train so với validation, test |
| RQ5 | Kết quả có ổn định qua seed và tuần kiểm tra không, và chênh lệch có ý nghĩa thống kê không? | Mọi thí nghiệm × 5 seed × 5 tuần; Wilcoxon, Diebold–Mariano |

So sánh với LightGBM, DLinear và TFT (RQ4 trong kế hoạch ban đầu) được để lại cho hướng phát triển (mục 9.3).

## 4. TỔNG QUAN NGHIÊN CỨU

### 4.1. Phương pháp học máy truyền thống

Fildes và cộng sự [4] tổng quan dự báo bán lẻ: dữ liệu chi tiết ở cấp sản phẩm cho phép gộp dữ liệu giữa các chuỗi (pooling), và khuyến mãi là một thách thức lớn. LightGBM [9] là bản cài đặt gradient boosting dùng lấy mẫu một phía theo gradient (GOSS) và gộp đặc trưng loại trừ (EFB). Trong cuộc thi M5 trên dữ liệu Walmart, mọi phương pháp top 50 là học máy và phần lớn dựa trên LightGBM [10]. Các mô hình này cần đặc trưng tạo thủ công (giá trị trễ, trung bình trượt) và mỗi tầm dự báo cần được thiết kế riêng để tránh rò rỉ thông tin.

### 4.2. Phương pháp học sâu

LSTM [7] bổ sung ô nhớ và các cổng để khắc phục hiện tượng tiêu biến gradient của RNN, cho phép học phụ thuộc với độ trễ dài. Salinas và cộng sự [6] đề xuất DeepAR, mạng hồi quy tự hồi quy huấn luyện trên nhiều chuỗi liên quan để dự báo xác suất, cho dự báo chính xác hơn các phương pháp hiện đại trên nhiều bộ dữ

liệu thực. Bandara và cộng sự [5] huấn luyện LSTM toàn cục trên chuỗi doanh số của Walmart.com, khai thác thông tin giữa các chuỗi trong phân cấp sản phẩm, đạt kết quả cạnh tranh ở mức ngành hàng và mức siêu bộ phận. Lim và cộng sự [8] đề xuất Temporal Fusion Transformer (TFT), kết hợp lớp hồi quy và self-attention, xử lý biến tĩnh và biến biết trước trong tương lai, có khả năng diễn giải. Với hàng tươi sống, Miguéis và cộng sự [3] dự báo nhu cầu cá tươi hằng ngày cho một cửa hàng, có xét nhu cầu bị kiểm duyệt; LSTM nhìn chung tốt nhất so với mạng truyền thẳng, SVR, Random Forest và Holt-Winters. Trong M5, đội hạng ba dùng tổ hợp 43 mạng nơ-ron nhiều lớp LSTM theo kiểu DeepAR; ở mức sản phẩm × cửa hàng, tổ hợp này đạt WRMSSE 0.875, thấp hơn đội thắng (0.884) [10].

### 4.3. Nhu cầu bị kiểm duyệt khi hết hàng

Conlon và Mortimer [1] cho thấy bỏ qua thay đổi về tính sẵn có của hàng làm lệch ước lượng nhu cầu. Wang và cộng sự [2] khôi phục nhu cầu theo giờ rồi dự báo 7 ngày; với TFT, WAPE giảm từ 31.75% (doanh số thô) xuống 29.02% (nhu cầu khôi phục bằng TimesNet). Đề tài dùng cách đơn giản hơn: loại ngày hết hàng nặng khỏi hàm mất mát.

### 4.4. Bộ dữ liệu và độ đo phổ biến

Dữ liệu thường dùng gồm M5 của Walmart (30,490 chuỗi sản phẩm × cửa hàng, 42,840 chuỗi khi tính cả các mức tổng hợp) [10], dữ liệu Walmart.com [5], ba bộ công khai parts, electricity, traffic và hai bộ thương mại điện tử của Amazon [6], và dữ liệu riêng của một nhà bán lẻ [3]. FreshRetailNet-50K khác các bộ trên ở chỗ có nhãn hết hàng theo giờ [2], [11]. Về độ đo, M5 dùng WRMSSE [10]; Miguéis và cộng sự dùng RMSE, MAE và MPE [3]; bài báo FreshRetailNet-50K dùng WAPE và WPE [2]. WAPE chia tổng sai số tuyệt đối cho tổng doanh số, nên không phụ thuộc thang đo và tính được khi có ngày doanh số bằng 0; vì vậy đề tài chọn WAPE làm độ đo chính, kèm MAE và RMSE.

### 4.5. Ưu điểm, hạn chế và khoảng trống

Mô hình cây như LightGBM mạnh trên dữ liệu bảng và dẫn đầu M5 [10], nhưng phụ thuộc đặc trưng tạo thủ công. Mô hình học sâu toàn cục học trực tiếp từ chuỗi và xử lý tự nhiên dự báo đa tầm và biến biết trước [6], [8], nhưng cần nhiều chuỗi liên quan và nhạy với khởi tạo. Khoảng trống: trên FreshRetailNet-50K chưa có đánh giá một LSTM toàn cục gọn ở mức ngày, và chưa đo đóng góp của khuyến mãi và thời tiết cho mô hình học sâu. Bảng 2 tóm tắt các nghiên cứu chính.

**Bảng 2:** *So sánh các nghiên cứu liên quan*

| Nghiên cứu | Dữ liệu | Phương pháp | Độ đo | Ưu điểm / hạn chế |
|---|---|---|---|---|
| Fildes et al. (2022) [4] | Tổng quan dự báo bán lẻ | Thống kê, học máy | – | Hệ thống hóa thực tiễn; không thực nghiệm mới |
| Makridakis et al. (2022) [10] | M5: 42,840 chuỗi Walmart | LightGBM, thống kê, học sâu | WRMSSE | LightGBM dẫn đầu; không xét hết hàng |
| Salinas et al. (2020) [6] | parts, electricity, traffic; thương mại điện tử Amazon | DeepAR (RNN tự hồi quy, toàn cục) | Độ chính xác dự báo xác suất | Chính xác hơn các phương pháp hiện đại; cần nhiều chuỗi liên quan |
| Bandara et al. (2019) [5] | Walmart.com, phân cấp sản phẩm | LSTM toàn cục + nhóm sản phẩm | Sai số dự báo | Khai thác thông tin giữa chuỗi; dữ liệu thương mại điện tử |
| Lim et al. (2021) [8] | Nhiều bộ dữ liệu thực | TFT (attention, đa tầm) | Sai số đa tầm dự báo | Diễn giải được; phức tạp, tốn tài nguyên |
| Miguéis et al. (2022) [3] | Cá tươi, một cửa hàng | LSTM, FNN, SVR, RF, Holt-Winters | RMSE, MAE, MPE | Có xét kiểm duyệt; một cửa hàng, dữ liệu riêng |
| Conlon & Mortimer (2013) [1] | Máy bán hàng tự động, trạng thái 4 giờ | Ước lượng nhu cầu kinh tế lượng | Độ lệch ước lượng | Chứng minh lệch do hết hàng; không phải dự báo |
| Wang et al. (2025) [2] | FreshRetailNet-50K | Khôi phục nhu cầu + SSA, TFT, DLinear | WAPE, WPE | Nhãn hết hàng theo giờ; mô hình nặng |

## 5. ĐỊNH NGHĨA BÀI TOÁN

Ký hiệu: i là chuỗi cửa hàng × sản phẩm, t là ngày; y(i,t) là doanh số ngày (sale_amount), c(i,t) là số giờ hết hàng từ 6:00 đến 22:00 (stock_hour6_22_cnt, 0–16); T là mốc dự báo (ngày quan sát cuối).

**Bảng 3:** *Đặc tả bài toán*

| Thành phần | Mô tả |
|---|---|
| Bài toán kinh doanh | Ước lượng nhu cầu 7 ngày tới để quyết định lượng đặt hàng hằng ngày cho hàng tươi sống |

| Thành phần | Mô tả |
|---|---|
| Đầu vào | Cửa sổ 28 ngày đến mốc T: doanh số, thứ trong tuần, holiday_flag, discount, activity_flag, bốn biến thời tiết; biến biết trước của 7 ngày T+1 … T+7 |
| Đầu ra | ŷ(i,T+1) … ŷ(i,T+7): vector 7 giá trị doanh số ngày |
| Loại tác vụ | Hồi quy có giám sát trên chuỗi thời gian, nhiều đầu ra; mô hình toàn cục học chung 1,000 chuỗi |
| Mục tiêu | Cực tiểu sai số bình phương trên ngày không bị loại (huấn luyện); WAPE thấp nhất trên 7 ngày kiểm tra 26/06–02/07/2024 |
| Tiêu chí thành công | LSTM vượt Seasonal Naive về WAPE, MAE và RMSE |

# 6. DỮ LIỆU

## 6.1. Thông tin chung

**Bảng 4:** *Thông tin chung về FreshRetailNet-50K*

| Thuộc tính | Giá trị |
|---|---|
| Tên, đơn vị phát hành | FreshRetailNet-50K; Dingdong (Trung Quốc), 2025 [2], [11] |
| Liên kết | https://huggingface.co/datasets/Dingdong-Inc/FreshRetailNet-50K |
| Giấy phép | CC BY 4.0 [11] |
| Quy mô gốc | 50,000 chuỗi cửa hàng × sản phẩm; 898 cửa hàng; 18 thành phố; 865 product_id |
| Thời gian | train: 28/03/2024 – 25/06/2024 (90 ngày); eval: 26/06/2024 – 02/07/2024 (7 ngày) |
| Số dòng gốc | train 4,500,000 = 50,000 × 90; eval 350,000 = 50,000 × 7 |
| Tập con dùng trong đề tài | 1,000 chuỗi × 97 ngày = 97,000 chuỗi – ngày |
| Số mẫu cho LSTM | 49,000 cửa sổ huấn luyện; 1,000 validation; 1,000 kiểm tra; 56,000 khi huấn luyện lại trên 90 ngày |
| Số đặc trưng đầu vào | 9 biến gốc theo ngày; sau mã hóa: 15 biến mỗi bước quá khứ, 14 biến biết trước mỗi ngày tương lai |
| Biến mục tiêu | sale_amount: doanh số ngày, số thực không âm, đã chuẩn hóa bởi đơn vị phát hành |
| Giá trị thiếu | Không có ở mọi cột (train và eval) |

## 6.2. Các trường dữ liệu và kiểu dữ liệu

Đề tài chỉ dùng dữ liệu theo ngày; hai mảng 24 giờ (hours_sale, hours_stock_status) không được sử dụng. Đây là bài toán hồi quy nên không có phân bố lớp.

**Bảng 5:** *Các trường dữ liệu sử dụng*

| Nhóm | Trường | Kiểu | Cách dùng |
|---|---|---|---|
| Định danh | store_id, product_id, management_group_id | Số nguyên | Xác định chuỗi; phân tầng khi lấy tập con |
| Thời gian | dt | Chuỗi ngày | Chia dữ liệu; sinh thứ trong tuần |
| Mục tiêu | sale_amount | Số thực ≥ 0 | Doanh số ngày; đầu vào và mục tiêu |
| Hết hàng | stock_hour6_22_cnt | Số nguyên 0–16 | Xác định ngày bị loại khỏi hàm mất mát |
| Khuyến mãi | discount, activity_flag | Số thực, 0/1 | Tỷ lệ giá (1.0 = không giảm); cờ khuyến mãi |
| Lịch | holiday_flag | 0/1 | Bằng 1 vào cuối tuần và ngày lễ |
| Thời tiết | precpt, avg_temperature, avg_humidity, avg_wind_level | Số thực | Mưa, nhiệt độ, độ ẩm, sức gió |

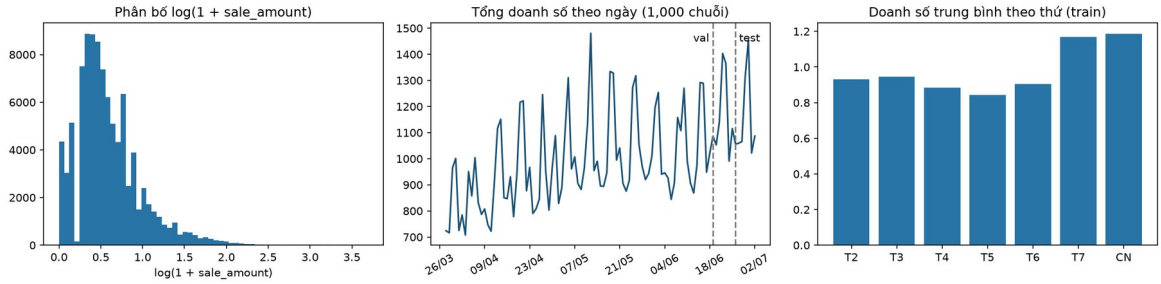
Tập con gồm 1,000 chuỗi, lấy mẫu phân tầng theo nhóm quản lý (7 nhóm) và mức hết hàng của chuỗi (ba nhóm theo tỷ lệ giờ hết hàng trên tập train), phân bổ theo tỷ lệ với seed 42. Tỷ lệ giờ hết hàng trung bình của tập con là 0.201, so với 0.199 của toàn bộ dữ liệu.

## 6.3. Khám phá dữ liệu

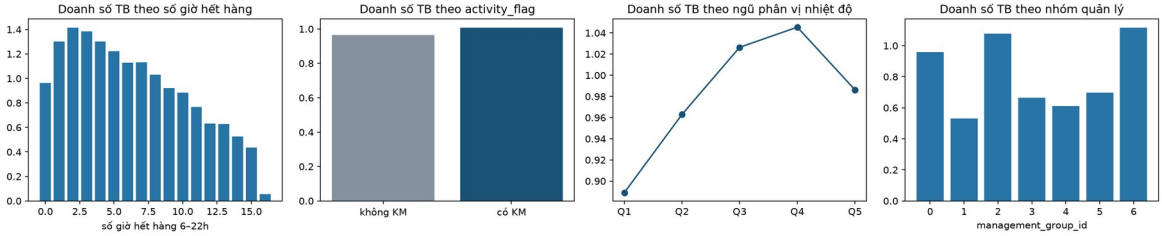
Số liệu dưới đây tính trên tập con với doanh số gốc: phân bố tính trên cả 97 ngày, các phân tích theo yếu tố tính trên 83 ngày huấn luyện.

- Phân bố: sale_amount lệch phải mạnh (độ lệch 8.71); trung vị 0.7, phân vị 99 là 5.8, lớn nhất 39.0; 4.46% chuỗi – ngày có doanh số bằng 0.
- Chu kỳ tuần: doanh số trung bình thứ Bảy 1.170 và Chủ nhật 1.187, cao hơn 1.41 lần so với ngày thấp nhất (thứ Năm, 0.843). holiday_flag bằng 1 ở 100% ngày thứ Bảy và 92.9% ngày Chủ nhật, nên trùng phần lớn với cuối tuần.
- Hết hàng: 55.6% ngày không có giờ hết hàng; 4.17% ngày hết hàng cả 16 giờ, với doanh số trung bình chỉ 0.055. Từ 2 giờ hết hàng trở lên, doanh số trung bình giảm dần theo số giờ hết hàng (1.415 ở 2 giờ, 0.436 ở 15 giờ).
- Khuyến mãi: ngày có activity_flag = 1 có doanh số trung bình 1.008, so với 0.965; ngày có discount ≤ 0.70 có doanh số trung bình 2.049, so với 0.820 khi không giảm giá.

- Thời tiết: tương quan hạng Spearman với doanh số đều nhỏ (lượng mưa −0.013, nhiệt độ 0.043, độ ẩm −0.033, sức gió −0.031). precpt dương ở 82,840 trong 83,000 chuỗi – ngày huấn luyện, nên phép chia có mưa và không mưa không mang nhiều thông tin.
- Nhóm quản lý: doanh số trung bình từ 0.532 (nhóm 1, 21 chuỗi) đến 1.117 (nhóm 6, 528 chuỗi); nhóm 0 có tỷ lệ ngày bằng 0 cao nhất (13.0%).




**Hình 1:** *Phân bố log(1 + doanh số), tổng doanh số theo ngày với ranh giới validation và kiểm tra, doanh số trung bình theo thứ*




**Hình 2:** *Doanh số trung bình theo số giờ hết hàng, activity_flag, nhiệt độ và nhóm quản lý (ngày huấn luyện)*

## 6.4. Chia dữ liệu theo thời gian

**Bảng 6:** *Kế hoạch chia dữ liệu*

| Tập | Khoảng thời gian | Số ngày | Chuỗi – ngày | Mục đích |
|---|---|---|---|---|
| Huấn luyện | 28/03/2024 – 18/06/2024 | 83 | 83,000 | Huấn luyện |
| Validation | 19/06/2024 – 25/06/2024 | 7 | 7,000 | Early stopping, chọn số epoch |
| Kiểm tra | 26/06/2024 – 02/07/2024 (tập eval) | 7 | 7,000 | Đánh giá cuối |

Mốc dự báo cho tập kiểm tra là 25/06/2024; không dùng thông tin sau mốc này, trừ các biến biết trước. Phần 2 thêm bốn tuần kiểm tra trượt trước tuần này (mục 7.6).

## 6.5. Tiền xử lý

- Giá trị thiếu: không có ở mọi cột, nhưng discount = 0 là không hợp lệ với định nghĩa tỷ lệ giá (0.36% dòng của toàn bộ tập train; 283 dòng trong tập con). Các giá trị này được coi là thiếu và điền bằng trung vị của sản phẩm cùng trạng thái activity_flag trên ngày huấn luyện; giá trị lớn hơn 1 được cắt về 1 (tập con không có).
- Hết hàng: khi sản phẩm hết hàng trong một phần của ngày, doanh số ghi nhận chỉ là cận dưới của nhu cầu thật (nhu cầu bị kiểm duyệt) [1]. Huấn luyện trực tiếp trên doanh số này khiến mô hình học mức nhu cầu thấp hơn thực tế [2]. Chuỗi – ngày có c(i,t) > 8 bị loại khỏi hàm mất mát và khỏi đánh giá chính, nhưng vẫn được dùng làm đầu vào. Tỷ lệ bị loại là 15.46% ở tập huấn luyện (12,830 chuỗi – ngày), 13.51% ở validation và 13.84% ở kiểm tra; doanh số trung bình của ngày bị loại là 0.577, so với 1.085 của ngày giữ lại.
- Ngoại lai: doanh số đầu vào của LSTM được chặn trên theo phân vị 99 của từng chuỗi, tính trên 83 ngày huấn luyện; mục tiêu và giá trị dùng để đánh giá giữ nguyên. Lý do: đỉnh nhu cầu là tín hiệu thật nên không xóa, nhưng một giá trị cực lớn trong cửa sổ đầu vào có thể chi phối trạng thái ẩn và hệ số chuẩn hóa của chuỗi. Có 791 trong 83,000 giá trị ngày huấn luyện bị chặn (0.95%); giá trị lớn nhất của đầu vào giảm từ 39.0 xuống 27.9.
- Chuẩn hóa: doanh số chia cho trung bình của chuỗi trên ngày huấn luyện (sau khi chặn), để mô hình toàn cục học được trên các chuỗi có quy mô khác nhau; dự báo được nhân lại để về đơn vị gốc. Bốn biến thời tiết chuẩn hóa z-score bằng trung bình và độ lệch chuẩn của ngày huấn luyện. discount nằm trong [0, 1] nên giữ nguyên.

## 6.6. Đặc trưng và cửa sổ cho LSTM

**Bảng 7:** *Đặc trưng đầu vào*

| Đặc trưng | Mã hóa | Số cột | Dùng ở |
|---|---|---|---|
| Doanh số | Chia trung bình chuỗi | 1 | Quá khứ |
| Thứ trong tuần | One-hot | 7 | Quá khứ, tương lai |
| holiday_flag | 0/1 | 1 | Quá khứ, tương lai |
| discount, activity_flag | Giữ nguyên | 2 | Quá khứ, tương lai (bỏ ở E3) |
| Thời tiết | z-score | 4 | Quá khứ, tương lai (bỏ ở E3) |

Mỗi mẫu gồm cửa sổ 28 ngày đến mốc T (28 × 15), biến biết trước của 7 ngày T+1 … T+7 (7 × 14), và mục tiêu là doanh số đã chuẩn hóa của 7 ngày đó kèm mặt nạ cho ngày bị loại. Mốc huấn luyện trượt từng ngày, cho 49 mẫu mỗi chuỗi; 46,604 trong 343,000 ô mục tiêu bị che. Mẫu validation có mốc T = 18/06/2024 (dự báo 19/06–25/06), mẫu kiểm tra có mốc T = 25/06/2024 (dự báo 26/06–02/07); mỗi chuỗi có một mẫu validation và một mẫu kiểm tra. Khi huấn luyện lại trên 90 ngày, mốc trượt đến 18/06/2024, cho 56 mẫu mỗi chuỗi. Ở E3, mỗi bước quá khứ còn 9 biến và mỗi ngày tương lai còn 8 biến.

# 7. PHƯƠNG PHÁP VÀ KẾ HOẠCH THỰC NGHIỆM

## 7.1. Lựa chọn phương pháp

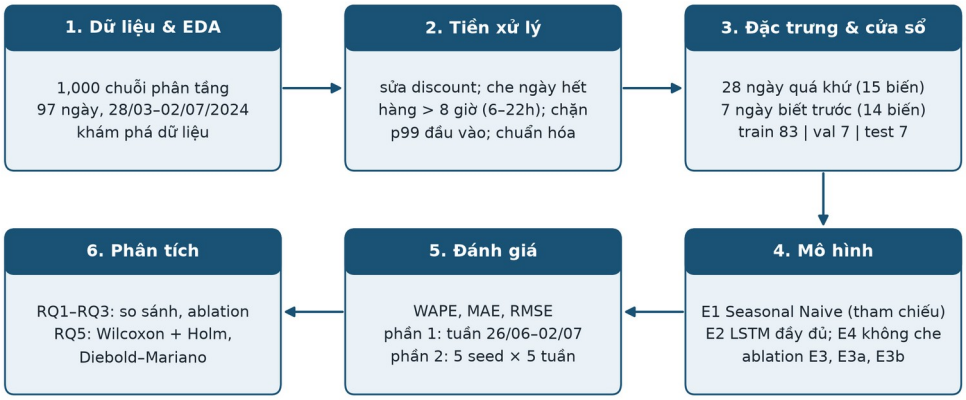
Mô hình chính là LSTM toàn cục, vì các lý do nêu ở mục 3.3 [7], [5]. Seasonal Naive 7 ngày, $\hat{y}(i,t) = y(i,t-7)$ với tuần cuối trước mốc dự báo được lặp lại, là mốc tham chiếu không học mà mô hình học phải vượt qua.

## 7.2. Kiến trúc và huấn luyện

**Bảng 8:** *Cấu hình mô hình LSTM*

| Thành phần | Cấu hình |
|---|---|
| Bộ mã hóa | Một lớp LSTM, 64 đơn vị ẩn, đọc cửa sổ 28 ngày |
| Đầu ra | Trạng thái ẩn cuối ghép với biến biết trước của 7 ngày (7 × 14), qua lớp kết nối đầy đủ 128 đơn vị (ReLU), ra 7 giá trị |
| Số tham số | 42,503 (E2); 35,591 (E3) |
| Hàm mất mát | MSE trên doanh số đã chuẩn hóa, có mặt nạ cho ngày bị loại |
| Tối ưu | Adam, tốc độ học 0.001, batch 256, tối đa 30 epoch |
| Early stopping | Theo WAPE validation, kiên nhẫn 4 epoch; sau đó huấn luyện lại trên 90 ngày với số epoch tốt nhất |
| Tái lập | Seed 42; PyTorch một luồng CPU, thuật toán tất định |

## 7.3. Quy trình tổng thể




**Hình 3:** *Quy trình từ dữ liệu đến đánh giá*

## 7.4. Thiết kế thực nghiệm

**Bảng 9:** *Thiết kế thực nghiệm*

| Thí nghiệm | Mô hình | Đầu vào | Mục đích |
|---|---|---|---|
| E1 | Seasonal Naive 7 ngày | y(i,t−7) | Mốc tham chiếu không học |
| E2 | LSTM | Đầy đủ (Bảng 7) | Mô hình chính (RQ1) |
| E3 | LSTM | Như E2, bỏ discount, activity_flag và thời tiết | Đóng góp chung của khuyến mãi và thời tiết (RQ2) |
| E3a | LSTM | Như E2, bỏ discount và activity_flag; giữ thời tiết và lịch | Đóng góp riêng của khuyến mãi (RQ3) |
| E3b | LSTM | Như E2, bỏ bốn biến thời tiết; giữ khuyến mãi và lịch | Đóng góp riêng của thời tiết, quá khớp (RQ3) |
| E4 | LSTM | Như E2, không loại ngày hết hàng khỏi hàm mất mát | Kiểm tra quy tắc hết hàng |

E2 so với E1 trả lời RQ1; E2 so với E3 trả lời RQ2; E2, E3a, E3b và E3 trả lời RQ3. E3a có 13 biến quá khứ và 12 biến biết trước; E3b có 11 và 10. Phần 1 chạy E1–E4 trên một lần chia; phần 2 chạy E1, E2, E3, E3a, E3b, E4 trên 5 seed × 5 tuần kiểm tra (RQ5). Mọi thí nghiệm dùng cùng tập con, cùng tiền xử lý và cùng độ đo.

### 7.5. Độ đo và notebook

Với y là doanh số thực, ŷ là dự báo, tổng lấy trên n chuỗi – ngày được đánh giá:

- WAPE = Σ|y − ŷ| / Σy: độ đo chính; không phụ thuộc thang đo, tính được khi có ngày doanh số bằng 0.
- MAE = (1/n) Σ|y − ŷ|: sai số trung bình theo đơn vị chuẩn hóa của dữ liệu.
- RMSE = √[(1/n) Σ(y − ŷ)²]: phạt nặng sai số lớn, nhạy với đỉnh nhu cầu.

Đánh giá chính dùng các chuỗi – ngày kiểm tra có c(i,t) ≤ 8 (6,031 trong 7,000), theo cùng quy tắc với tập huấn luyện; kết quả trên toàn bộ 7,000 chuỗi – ngày được báo cáo kèm. WAPE được tách theo tầm dự báo h = 1…7 và theo ngày có hoặc không có khuyến mãi.

Notebook phần 1 (FreshRetailNet_LSTM.ipynb) in dữ liệu trước và sau từng bước xử lý và chạy khoảng 90 giây trên CPU. Notebook phần 2 (FreshRetailNet_LSTM_Part2.ipynb) dùng lại quy trình đó và chạy 125 lần huấn luyện LSTM bằng 6 tiến trình song song, mỗi tiến trình một luồng PyTorch.

### 7.6. Đánh giá trượt và kiểm định thống kê (phần 2)

Mỗi thí nghiệm LSTM được chạy với 5 seed (42–46) trên 5 tuần kiểm tra liên tiếp (walk-forward). Với tuần kiểm tra bắt đầu ở ngày s, mô hình học trên mục tiêu đến ngày s − 8, dùng tuần s − 7 … s − 1 để early stopping, sau đó huấn luyện lại đến ngày s − 1 với số epoch tốt nhất và dự báo tuần s … s + 6 từ mốc s − 1. Sửa discount, ngưỡng p99, hệ số chuẩn hóa chuỗi và thống kê z-score của thời tiết được tính lại cho từng tuần, chỉ từ ngày huấn luyện của tuần đó, nên không rò rỉ thông tin. Tuần thứ 5 trùng với lần chia của phần 1.

**Bảng 10:** *Năm tuần kiểm tra trượt*

| Tuần | Huấn luyện (mục tiêu) | Validation | Kiểm tra | Mốc huấn luyện mỗi chuỗi | Chuỗi – ngày được đánh giá |
|---|---|---|---|---|---|
| 1 | 28/03 – 21/05 | 22/05 – 28/05 | 29/05 – 04/06 | 21 | 6,155 |
| 2 | 28/03 – 28/05 | 29/05 – 04/06 | 05/06 – 11/06 | 28 | 6,035 |
| 3 | 28/03 – 04/06 | 05/06 – 11/06 | 12/06 – 18/06 | 35 | 6,001 |
| 4 | 28/03 – 11/06 | 12/06 – 18/06 | 19/06 – 25/06 | 42 | 6,054 |
| 5 | 28/03 – 18/06 | 19/06 – 25/06 | 26/06 – 02/07 | 49 | 6,031 |

Kết quả được tóm tắt bằng trung bình ± độ lệch chuẩn của WAPE, MAE và RMSE qua 25 lần chạy. Kiểm định so sánh E2 với từng mô hình khác (5 cặp) theo ba cách, với $\alpha = 0.05$ và hiệu chỉnh Holm trong mỗi họ 5 kiểm định:

- Chính: Wilcoxon signed-rank trên MAE theo chuỗi (n = 1,000), trong đó MAE của mỗi chuỗi lấy trung bình qua 5 seed và gộp các ngày được đánh giá của 5 tuần. Độ lớn hiệu ứng: trung vị chênh lệch, % thay đổi MAE trung bình và tương quan rank-biserial $r = (R^+ - R^-)/(R^+ + R^-)$.
- Phụ 1: Diebold–Mariano trên chênh lệch sai số tuyệt đối trung bình theo ngày (35 ngày kiểm tra liên tiếp). Giả định chuỗi chênh lệch dừng theo hiệp phương sai; vì 7 ngày trong một tuần cùng một mốc dự báo, phương sai dùng ước lượng HAC Newey–West với độ trễ $h - 1 = 6$, kèm hiệu chỉnh mẫu nhỏ Harvey–Leybourne–Newbold và phân phối t với 34 bậc tự do.
- Phụ 2: Wilcoxon signed-rank trên WAPE theo cặp lần chạy (n = 25). Các lần chạy cùng tuần không độc lập, nên kiểm định này chỉ dùng để kiểm tra độ vững.

Tính tất định được kiểm tra trong notebook: chạy E2 với seed 42 ở tuần 5 hai lần cho dự báo giống hệt, và WAPE (0.3248) trùng với phần 1.

# 8. KẾT QUẢ KỲ VỌNG VÀ KẾT QUẢ THỰC NGHIỆM

## 8.1. Kết quả kỳ vọng (giả thuyết)

Trước khi chạy, nhóm đặt các giả thuyết sau:

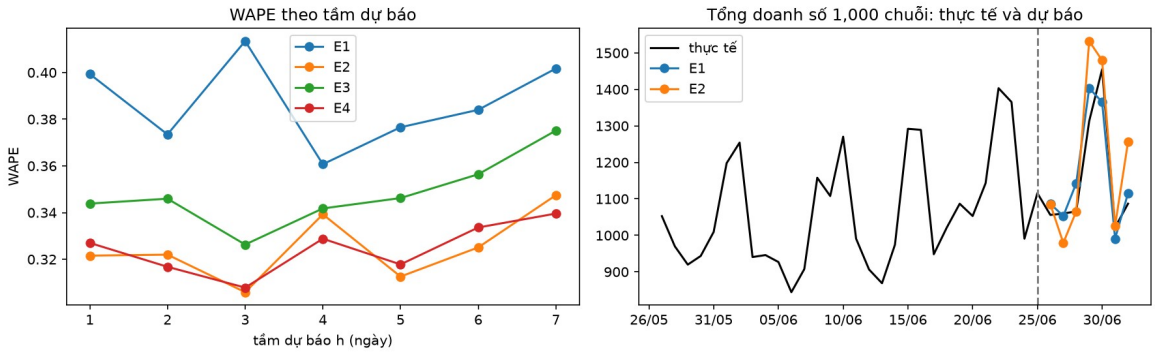
- H1 (RQ1): LSTM có WAPE, MAE và RMSE thấp hơn Seasonal Naive 7 ngày.
- H2 (RQ2): bỏ khuyến mãi và thời tiết (E3) làm tăng WAPE so với E2, rõ nhất ở ngày có khuyến mãi.
- H3 (RQ3): bỏ riêng khuyến mãi (E3a) hoặc riêng thời tiết (E3b) đều làm tăng sai số so với E2, nhưng ít hơn E3; khuyến mãi đóng góp nhiều hơn thời tiết, vì EDA cho thấy thời tiết tương quan rất yếu với doanh số. Thêm thời tiết làm khoảng cách test − train của E2 lớn hơn của E3b.
- H5 (RQ5): ưu thế của E2 so với E1 ổn định qua seed và tuần kiểm tra và có ý nghĩa thống kê; chênh lệch giữa các biến thể LSTM nhỏ, cần kiểm định để kết luận.

## 8.2. Phần 1: kết quả trên một lần chia

**Bảng 11:** *Kết quả trên 7 ngày kiểm tra (seed 42)*

| Thí nghiệm | WAPE | MAE | RMSE | WAPE giảm so với E1 | WAPE (toàn bộ ngày) |
|---|---|---|---|---|---|
| E1 Seasonal Naive | 0.3859 | 0.4780 | 0.7893 | – | 0.4306 |
| E2 LSTM đầy đủ | 0.3248 | 0.4023 | 0.6553 | 15.8% | 0.3782 |
| E3 LSTM bỏ khuyến mãi, thời tiết | 0.3476 | 0.4306 | 0.7768 | 9.9% | 0.3965 |
| E4 LSTM không loại ngày hết hàng (phụ) | 0.3243 | 0.4017 | 0.6940 | 16.0% | 0.3737 |

Số liệu của notebook phần 1, một lần chạy với seed 42. Ba cột độ đo đầu tính trên 6,031 chuỗi – ngày có c(i,t) ≤ 8; cột cuối tính trên toàn bộ 7,000 chuỗi – ngày. Ở ngày có khuyến mãi, WAPE của E2 là 0.3078 và của E3 là 0.3479; ở ngày không khuyến mãi là 0.3328 và 0.3474. E2 thấp hơn E1 ở cả 7 tầm dự báo (Hình 4).




**Hình 4:** *Phần 1: WAPE theo tầm dự báo và tổng doanh số 1,000 chuỗi (thực tế, E1 và E2)*

## 8.3. RQ3: đóng góp riêng của khuyến mãi và thời tiết

Các số liệu từ mục này trở đi lấy từ notebook phần 2, trung bình qua 25 lần chạy (5 seed × 5 tuần kiểm tra).

**Bảng 12:** *RQ3: ablation qua 25 lần chạy*

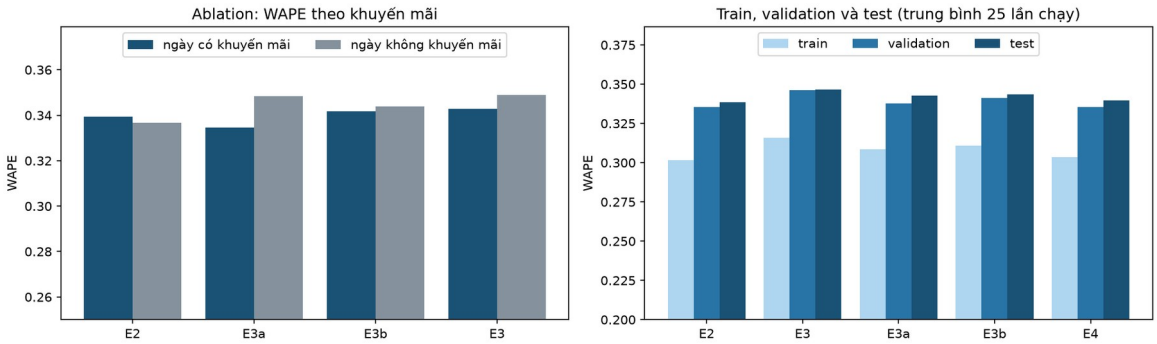
| Thí nghiệm | WAPE (TB ± ĐLC) | MAE | RMSE | WAPE ngày có KM | WAPE ngày không KM | ΔWAPE so với E2 |
|---|---|---|---|---|---|---|
| E2 đầy đủ | 0.3386 ± 0.0160 | 0.3927 | 0.6800 | 0.3394 | 0.3367 | – |
| E3a bỏ khuyến mãi | 0.3428 ± 0.0171 | 0.3978 | 0.6792 | 0.3345 | 0.3484 | +0.0043 |
| E3b bỏ thời tiết | 0.3436 ± 0.0100 | 0.3988 | 0.7054 | 0.3417 | 0.3438 | +0.0050 |
| E3 bỏ cả hai | 0.3466 ± 0.0113 | 0.4025 | 0.6977 | 0.3429 | 0.3489 | +0.0080 |

Bỏ riêng khuyến mãi làm WAPE tăng 0.0043 (E3a tệ hơn E2 ở 17/25 lần chạy); bỏ riêng thời tiết làm WAPE tăng 0.0050 (18/25); bỏ cả hai tăng 0.0080 (18/25). Hai mức tăng riêng gần bằng nhau và tổng của chúng (0.0093) lớn hơn mức tăng khi bỏ cả hai, nên hai nhóm có phần thông tin trùng nhau. Khác với một lần chia ở phần 1, E3a không tệ hơn E2 ở ngày có khuyến mãi (0.3345 so với 0.3394); phần tăng sai số của E3a nằm ở ngày không khuyến mãi (0.3484 so với 0.3367). Thời tiết có tương quan hạng Spearman rất yếu với doanh số trên 83 ngày huấn luyện (lượng mưa −0.013, nhiệt độ 0.043, độ ẩm −0.033, sức gió −0.031), trong khi discount là −0.193 và activity_flag là 0.112.

**Bảng 13:** *RQ3: sai số train, validation và test*

| Thí nghiệm | WAPE train | WAPE validation | WAPE test | Test − train (TB ± ĐLC) | Epoch tốt nhất (TB) |
|---|---|---|---|---|---|
| E2 | 0.3015 | 0.3354 | 0.3386 | 0.0371 ± 0.0194 | 6.2 |
| E3 | 0.3159 | 0.3461 | 0.3466 | 0.0307 ± 0.0106 | 4.1 |
| E3a | 0.3084 | 0.3378 | 0.3428 | 0.0344 ± 0.0169 | 6.6 |
| E3b | 0.3108 | 0.3411 | 0.3436 | 0.0328 ± 0.0120 | 3.4 |
| E4 | 0.3036 | 0.3353 | 0.3396 | 0.0360 ± 0.0177 | 4.9 |

WAPE train là sai số trong mẫu của mô hình đã huấn luyện lại, trên các cửa sổ huấn luyện; WAPE validation là giá trị tốt nhất khi early stopping. Thêm thời tiết làm sai số train giảm từ 0.3108 (E3b) xuống 0.3015 (E2) nhưng sai số test chỉ giảm từ 0.3436 xuống 0.3386; khoảng cách test − train của E2 lớn hơn E3b trung bình 0.0042 và lớn hơn ở 16/25 lần chạy. Đây là dấu hiệu quá khớp nhẹ do bốn biến thời tiết, không phải quá khớp nặng: sai số validation và test của mọi biến thể chênh nhau dưới 0.006.



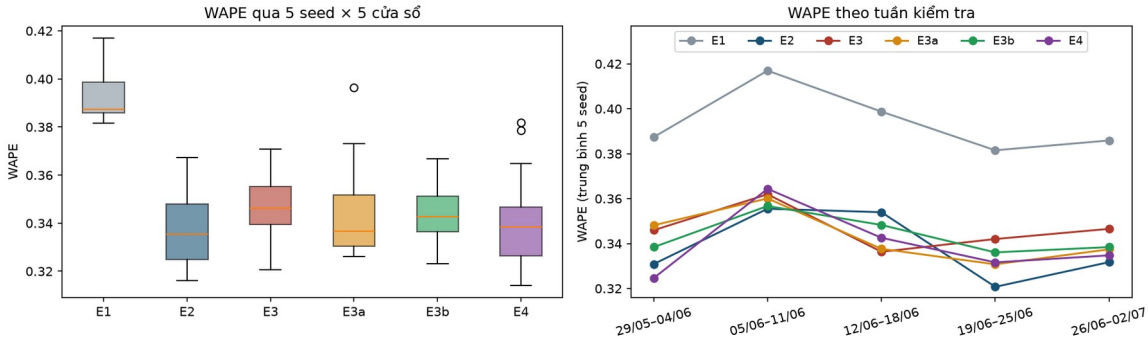

**Hình 5:** *RQ3: WAPE theo ngày có và không có khuyến mãi (trái); WAPE train, validation và test trung bình 25 lần chạy (phải)*

## 8.4. RQ5: độ ổn định qua seed và tuần kiểm tra

**Bảng 14:** *RQ5: trung bình ± độ lệch chuẩn qua 5 seed × 5 tuần*

| Thí nghiệm | WAPE | MAE | RMSE | WAPE giảm so với E1 |
|---|---|---|---|---|
| E1 Seasonal Naive | 0.3941 ± 0.0130 | 0.4573 ± 0.0207 | 0.7615 ± 0.0366 | – |
| E2 LSTM đầy đủ | 0.3386 ± 0.0160 | 0.3927 ± 0.0188 | 0.6800 ± 0.0422 | 14.1% |
| E3 bỏ khuyến mãi, thời tiết | 0.3466 ± 0.0113 | 0.4025 ± 0.0247 | 0.6977 ± 0.0672 | 12.1% |
| E3a bỏ khuyến mãi | 0.3428 ± 0.0171 | 0.3978 ± 0.0224 | 0.6792 ± 0.0690 | 13.0% |
| E3b bỏ thời tiết | 0.3436 ± 0.0100 | 0.3988 ± 0.0205 | 0.7054 ± 0.0634 | 12.8% |
| E4 không loại ngày hết hàng | 0.3396 ± 0.0167 | 0.3942 ± 0.0253 | 0.7011 ± 0.0743 | 13.8% |

Mỗi dòng gồm 25 lần chạy; E1 không học nên độ lệch chuẩn của E1 chỉ phản ánh khác biệt giữa các tuần. E2 tốt hơn E1 ở cả 25/25 lần chạy, và WAPE trung bình giảm 14.1%, gần với mức 15.8% của một lần chia ở phần 1. Độ lệch chuẩn WAPE giữa các seed trong cùng một tuần, lấy trung bình qua 5 tuần, là 0.0078 (E2), 0.0077 (E3), 0.0114 (E3a), 0.0063 (E3b) và 0.0087 (E4), cùng cỡ với chênh lệch giữa các biến thể LSTM. Thứ hạng giữa các biến thể đổi theo tuần: ở tuần 12/06–18/06, E2 (0.3540) tệ hơn E3 (0.3363) (Hình 6).




**Hình 6:** *RQ5: phân bố WAPE qua 25 lần chạy (trái) và WAPE trung bình 5 seed theo tuần kiểm tra (phải)*

**Bảng 15:** *RQ5: Wilcoxon trên MAE theo chuỗi (n = 1,000), hiệu chỉnh Holm*

| Cặp | MAE E2 | MAE mô hình kia | Thay đổi MAE của E2 | Trung vị d | Chuỗi E2 tốt hơn | Rank-biserial | p (Holm) |
|---|---|---|---|---|---|---|---|
| E2 – E1 | 0.3920 | 0.4597 | −14.7% | 0.0627 | 85.8% | 0.78 | 8.0e−101 |
| E2 – E3 | 0.3920 | 0.4024 | −2.6% | 0.0042 | 56.3% | 0.19 | 2.8e−07 |
| E2 – E3a | 0.3920 | 0.3975 | −1.4% | 0.0044 | 59.9% | 0.26 | 8.0e−12 |
| E2 – E3b | 0.3920 | 0.3987 | −1.7% | −0.0013 | 47.0% | 0.01 | 1.00 |
| E2 – E4 | 0.3920 | 0.3945 | −0.6% | 0.0005 | 51.9% | 0.01 | 1.00 |

d = MAE của mô hình kia − MAE của E2 trên cùng chuỗi (trung bình 5 seed, gộp 5 tuần); d > 0 nghĩa là E2 tốt hơn. Với α = 0.05 sau hiệu chỉnh Holm, E2 tốt hơn có ý nghĩa so với E1 (hiệu ứng lớn, rank-biserial 0.78), so với E3 và E3a (hiệu ứng nhỏ, 0.19 và 0.26). So với E3b và E4 không có khác biệt: MAE trung bình của E3b cao hơn 1.7% nhưng trung vị d âm và chỉ 47.0% chuỗi tốt hơn với E2, tức phần chênh lệch đến từ một số ít chuỗi.

**Bảng 16:** *RQ5: kiểm định phụ (Diebold–Mariano và Wilcoxon theo lần chạy)*

| Cặp | DM (HLN), n = 35 ngày | p (Holm) DM | ΔWAPE TB, n = 25 | E2 tốt hơn | p (Holm) Wilcoxon 25 lần |
|---|---|---|---|---|---|
| E2 – E1 | 15.54 | 2.6e−16 | 0.0556 | 25/25 | 3.0e−07 |
| E2 – E3 | 1.52 | 0.41 | 0.0080 | 18/25 | 0.088 |
| E2 – E3a | 0.94 | 0.71 | 0.0043 | 17/25 | 0.50 |
| E2 – E3b | 1.92 | 0.25 | 0.0050 | 18/25 | 0.12 |
| E2 – E4 | 0.42 | 0.71 | 0.0010 | 12/25 | 0.92 |

Ở mức tổng hợp theo ngày hoặc theo lần chạy, chỉ khác biệt E2 – E1 có ý nghĩa. Các khác biệt giữa E2 và E3, E3a nhất quán ở mức chuỗi nhưng nhỏ so với dao động giữa các ngày và các tuần, nên không vượt ngưỡng khi chỉ có 35 ngày hoặc 25 lần chạy.

## 8.5. Đối chiếu giả thuyết

- H1 được ủng hộ: E2 tốt hơn E1 ở một lần chia (WAPE 0.3248 so với 0.3859) và ở cả 25/25 lần chạy trượt (0.3386 ± 0.0160 so với 0.3941 ± 0.0130); khác biệt có ý nghĩa ở cả ba kiểm định.
- H2 được ủng hộ một phần: bỏ khuyến mãi và thời tiết làm WAPE tăng ở một lần chia (0.3248 lên 0.3476) và trung bình qua 25 lần chạy (0.3386 lên 0.3466); khác biệt có ý nghĩa ở mức chuỗi nhưng không có ý nghĩa ở mức ngày (DM) và mức lần chạy. Việc mức tăng tập trung ở ngày có khuyến mãi chỉ thấy ở tuần cuối, không lặp lại khi trung bình qua 5 tuần.
- H3 được ủng hộ một phần: bỏ riêng từng nhóm đều làm tăng WAPE và ít hơn bỏ cả hai. Khuyến mãi đóng góp ổn định hơn thời tiết ở mức chuỗi (E2 – E3a có ý nghĩa, E2 – E3b thì không), nhưng mức giảm WAPE trung bình của hai nhóm gần bằng nhau. Thời tiết làm khoảng cách test − train tăng nhẹ (0.0371 so với 0.0328).
- H5 được ủng hộ: ưu thế của LSTM so với Seasonal Naive ổn định; khác biệt giữa các biến thể LSTM cùng cỡ với dao động theo seed và đổi thứ hạng theo

tuần. Quy tắc loại ngày hết hàng (E4) không tạo khác biệt có ý nghĩa về WAPE hoặc MAE, nhưng RMSE trung bình của E4 cao hơn (0.7011 so với 0.6800).

# 9. ĐÓNG GÓP, HẠN CHẾ VÀ HƯỚNG PHÁT TRIỂN

## 9.1. Đóng góp

Đề tài đóng góp một LSTM toàn cục gọn cho dự báo nhu cầu hàng tươi sống theo ngày trên dữ liệu công khai, giảm WAPE 14.1% so với Seasonal Naive trung bình qua 5 seed × 5 tuần kiểm tra trượt; một phép đo tách riêng đóng góp của khuyến mãi và thời tiết, kèm kiểm định có hiệu chỉnh Holm và độ lớn hiệu ứng; và hai notebook tái lập trên CPU (phần 1 khoảng 90 giây, phần 2 khoảng 14–20 phút với 6 tiến trình song song).

## 9.2. Hạn chế và rủi ro

- Một bộ dữ liệu và một tập con 1,000 chuỗi; kết quả chưa được kiểm chứng trên toàn bộ 50,000 chuỗi hay bộ dữ liệu khác.
- Lịch sử ngắn (97 ngày): tuần kiểm tra đầu tiên chỉ có 21 mốc huấn luyện mỗi chuỗi.
- K = 5 tuần và 5 seed: kiểm định ở mức ngày (35 ngày) và mức lần chạy (25 lần) có lực thấp; 5 lần chạy cùng tuần không độc lập, và E1 được lặp lại cho mỗi seed.
- Các tuần kiểm tra dùng chung phần lớn dữ liệu huấn luyện, nên không phải các mẫu độc lập.
- Ngày hết hàng một phần vẫn bị kiểm duyệt; thời tiết tương lai được giả định là đã biết, như trong bài báo gốc [2].

## 9.3. Hướng phát triển và kết luận

Giai đoạn sau: so sánh LSTM với LightGBM, DLinear và TFT trên cùng tập con và cùng các tuần kiểm tra (câu hỏi RQ4 được để lại); khôi phục nhu cầu theo giờ; chạy trên 50,000 chuỗi với nhiều tuần kiểm tra hơn; và thêm lớp quyết định tồn kho.

Kết luận: mạng LSTM toàn cục dự báo nhu cầu 7 ngày chính xác hơn Seasonal Naive một cách ổn định và có ý nghĩa thống kê. Khuyến mãi và thời tiết cùng giúp giảm sai số khoảng 0.008 WAPE; đóng góp của khuyến mãi nhất quán hơn ở mức chuỗi, còn thời tiết có đóng góp nhỏ và làm mô hình quá khớp nhẹ. Các khác biệt

cỡ dưới 0.01 WAPE giữa các biến thể LSTM nằm trong dao động theo seed và theo tuần.

## TÀI LIỆU THAM KHẢO


[1] C. T. Conlon and J. H. Mortimer, "Demand estimation under incomplete product availability," *American Economic Journal: Microeconomics*, vol. 5, no. 4, pp. 1–30, 2013, doi: 10.1257/mic.5.4.1.

[2] Y. Wang, J. Gu, L. Long, X. Li, L. Shen, Z. Fu, X. Zhou, and X. Jiang, "FreshRetailNet-50K: A stockout-annotated censored demand dataset for latent demand recovery and forecasting in fresh retail," arXiv:2505.16319, 2025. [Online]. Available: https://arxiv.org/abs/2505.16319

[3] V. L. Miguéis, A. Pereira, J. Pereira, and G. Figueira, "Reducing fresh fish waste while ensuring availability: Demand forecast using censored data and machine learning," *Journal of Cleaner Production*, vol. 359, Art. no. 131852, 2022, doi: 10.1016/j.jclepro.2022.131852.

[4] R. Fildes, S. Ma, and S. Kolassa, "Retail forecasting: Research and practice," *International Journal of Forecasting*, vol. 38, no. 4, pp. 1283–1318, 2022, doi: 10.1016/j.ijforecast.2019.06.004.

[5] K. Bandara, P. Shi, C. Bergmeir, H. Hewamalage, Q. Tran, and B. Seaman, "Sales demand forecast in e-commerce using a long short-term memory neural network methodology," in *Neural Information Processing (ICONIP 2019)*, T. Gedeon, K. W. Wong, and M. Lee, Eds., Lecture Notes in Computer Science, vol. 11955. Cham, Switzerland: Springer, 2019, pp. 462–474, doi: 10.1007/978-3-030-36718-3_39.

[6] D. Salinas, V. Flunkert, J. Gasthaus, and T. Januschowski, "DeepAR: Probabilistic forecasting with autoregressive recurrent networks," *International Journal of Forecasting*, vol. 36, no. 3, pp. 1181–1191, 2020, doi: 10.1016/j.ijforecast.2019.07.001.

[7] S. Hochreiter and J. Schmidhuber, "Long short-term memory," *Neural Computation*, vol. 9, no. 8, pp. 1735–1780, 1997, doi: 10.1162/neco.1997.9.8.1735.

[8] B. Lim, S. Ö. Arık, N. Loeff, and T. Pfister, "Temporal Fusion Transformers for interpretable multi-horizon time series forecasting," *International Journal of Forecasting*, vol. 37, no. 4, pp. 1748–1764, 2021, doi: 10.1016/j.ijforecast.2021.03.012.

[9] G. Ke *et al.*, "LightGBM: A highly efficient gradient boosting decision tree," in *Advances in Neural Information Processing Systems 30*, 2017. [Online]. Available: https://proceedings.neurips.cc/paper/2017/hash/6449f44a102fde848669bdd9eb6b76fa-Abstract.html

[10] S. Makridakis, E. Spiliotis, and V. Assimakopoulos, "M5 accuracy competition: Results, findings, and conclusions," *International Journal of Forecasting*, vol. 38, no. 4, pp. 1346–1364, 2022, doi: 10.1016/j.ijforecast.2021.11.013.

[11] Dingdong-Inc, "FreshRetailNet-50K," Hugging Face dataset card, v1.0, 2025. [Online]. Available: https://huggingface.co/datasets/Dingdong-Inc/FreshRetailNet-50K